

Vorhersagebasierte Suche für autonomes Spielen¹

Alexander Dockhorn²

Abstract: Lernverfahren befähigen einen Agenten autonom eine für ihn unbekannte Umgebung zu explorieren und ihm gestellte Aufgaben zu erfüllen. Hierbei erlauben Modell-bildende Verfahren dem Agenten, ein geistiges Abbild seiner Umgebung zu konstruieren und in diesem das Resultat seiner Handlungen vorherzusehen. Die Konstruktion und Verwendung eines solchen Modells stellt die Schwerpunkte meiner Dissertation dar. Hierfür wird zunächst eine theoretische Grundlage für die Dekomposition von Forward Modellen geschaffen. Darauf basierend werden das Local Forward Model sowie das Object-based Forward Model als effiziente Modellheuristiken abgeleitet. Besonderes Augenmerk wird zudem auf die Modellierung unsicherer Informationen gelegt. Abschließend werden Anwendungen im Bereich der künstlichen Intelligenz in Spielen und der Robotik für die entwickelten Verfahren demonstriert.

1 Einführung

Die Entwicklung von künstlicher allgemeiner Intelligenz ist eines der wichtigsten langfristigen Ziele in der Forschung zur künstlichen Intelligenz (KI). Dazu gehört die Entwicklung von intelligenten Algorithmen, die eine Vielzahl von Problemen bewältigen können. Während KI-Methoden in den letzten Jahren viele erfolgreiche Anwendungen hervorgebracht haben, sind die Fähigkeiten dieser Agenten oft auf sehr spezifische Problemszenarien beschränkt. In Anbetracht der Tatsache, dass das menschliche Gehirn in der Lage ist, komplex zu denken und sich an neue Kontexte, Aufgaben und Umgebungen anzupassen, hinkt die KI-Forschung bei der Entwicklung von vergleichbar flexibel anwendbaren Computeragenten dem natürlichen Vorbild hinterher.

Die Forschung in der künstlichen allgemeinen Intelligenz kann in die modellorientierte und die anwendungsorientierte Sichtweise unterteilt werden. Bei der modellorientierten Sichtweise werden die Fähigkeiten des menschlichen Gehirns analysiert und teilweise kopiert. Im Gegensatz dazu werden bei der anwendungsorientierten Sichtweise Lösungen durch die Analyse von immer komplexeren Problemen erstellt. Während jede dieser Lösungen oft auf eine bestimmte Anwendung beschränkt ist, sind die Anwendungen im Laufe der Jahre immer fortschrittlicher geworden. Der Vorteil dieses Ansatzes liegt in der Vergleichbarkeit der entwickelten Lösungen auf Basis der jeweiligen Aufgabenstellung.

Spiele, insbesondere digitale Spiele, stellen nützliche Werkzeuge bei der Entwicklung und Bewertung von KI-Agenten dar. Nicht nur verfügen sie über klare und quantifizierbare Ziele, sondern erfordern auch komplexe Entscheidungsprozesse. Digitale Spiele haben zudem den

¹ Englischer Titel der Dissertation: "Prediction-based Search for Autonomous Game-Playing"

² Lehrstuhl für Computational Intelligence, Fakultät für Informatik, Otto-von-Guericke-Universität Magdeburg, E-Mail: alexander.dockhorn@ovgu.de; Website: <https://adockhorn.github.io/>

Vorteil, dass sie für Computer vollständig zugänglich sind und wir ihre Ein- und Ausgabe ohne großen technischen Aufwand konfigurieren können. Da Spiele auch von menschlichen Spielern gespielt werden, ermöglichen sie interessante Mensch-Computer-Interaktionen und liefern uns große Datensätze des menschlichen Spielverhaltens.

Nachdem viele Jahre die Entwicklung eines KI-Agenten für ein einzelnes Spiel im Fokus der Forschung stand (vgl. Entwicklungen von Schach und Go Agenten), gewinnt die Entwicklung eines einzelnen Agenten, der in der Lage ist, mehrere Spiele zu spielen, zunehmend an Popularität und wird als vielversprechender nächster Schritt zur Verbesserung der Fähigkeiten von KI-Agenten gesehen [Le13]. Im Rahmen der Evaluierung der allgemeinen Spielfähigkeiten eines Agenten erhält er jeweils eine Beschreibung des aktuellen Spiels in Form seines Zustands- und Aktionsraums sowie des Regelwerks. Während der Entwicklungsphase des Agenten sind diese Informationen unbekannt, sodass der Agent selbst lernen muss, wie er diese nutzen kann, um die Spiele effektiv zu spielen. Diese Aufgabe erfordert, dass der Agent Algorithmen zur Wissensrepräsentation, des Lernens, des Schlussfolgerns und der Entscheidungsfindung kombiniert [GLP05], wodurch die notwendige Expertise für das Spielen des Spiels vom Entwickler des Agenten auf den Agenten selbst verlagert wird.

1.1 Übersicht zu Existierenden Lernverfahren

Zunächst wird ein kurzer Überblick über bereits existierende Lösungen der künstlichen Intelligenz in Spielen gegeben, um die im Rahmen meiner Dissertation entwickelten Verfahren in den Forschungskontext einzubetten.

Grundlage der Betrachtungen ist das Agent-Environment Interface [SB18], welches die fünf Komponenten *Agent*, *Umgebung*, *Zustand der Umgebung*, *Aktionen des Agenten* und dessen *Belohnung* umfasst. Der Agent interagiert durch die Ausführung von Aktionen $a \in \mathcal{A}$ mit seiner Umgebung. In Folge dessen verändert sich ihr Zustand $s \in \mathcal{S}$ und der Agent erhält eine numerische Belohnung r , welche über den Erfolg bzw. Misserfolg im Erfüllen der ihm gestellten Aufgabe informiert. Ein solcher Prozess wird als Markov-Entscheidungsproblem modelliert, welches den Zustandsübergang und die Belohnung als Wahrscheinlichkeitsverteilung über die Sequenz der vorherigen Zustände und Aktionen definiert:

$$P(S_{t+1}, R_{t+1} \mid S_0, A_0, \dots, S_t, A_t)$$

Das Umgebungsmodell kann in ein Zustandsübergangs- und ein Belohnungsmodell aufgeteilt werden:

$$\begin{aligned} \text{Zustandsübergangsmodell: } & p(s_t \mid s_{t-1}, a_{t-1}, \dots, s_{t-m}, a_{t-m}) \\ \text{Belohnungsmodell: } & q(r_t \mid s_{t-1}, a_{t-1}, \dots, s_{t-m}, a_{t-m}) \end{aligned}$$

Aus dieser Aufteilung ergeben sich zwei grundlegende Betrachtungsweisen auf das Lernproblem. Während Reinforcement Learning Algorithmen sich auf die Belohnungsverteilung fokussieren, nutzen Model Learning Verfahren die Informationen vorangegangener Interaktionen um das Zustandsübergangsmodell zu approximieren. Letzteres kann dann in




Abb. 1: Vergleich von allgemeinen Lernverfahren basierend auf dem Wissen des Agenten über das Belohnungsmodell und das Zustandsübergangsmodell [Do20].

Verbindung mit Such- und Planungsalgorithmen verwendet werden, um den Wert einer Aktion anhand der zu erwartenden Ergebnisse zu bestimmen.

Der Einsatz von Planungs- bzw. Suchalgorithmen setzt die Kenntnis des Zustandsübergangsmodells voraus. Ist ein solches bekannt, haben Verfahren wie z.B. Monte Carlo Tree Search (MCTS) [Br12] und der Rolling Horizon Evolutionary Algorithm (RHEA) [GLP17] bereits gute Leistungen in einer Vielzahl von Spielen erbringen können [Pe19]. Hingegen ist der Einsatz von tabellarischen Reinforcement Learning Algorithmen [SB18] auf einfache Zustands- und Aktionsräume begrenzt. Unter Verwendung von tiefen neuronalen Netzen konnte durch die Approximation des Belohnungsmodells eine breitere Anwendbarkeit erreicht werden [Mn15]. Die in dieser Arbeit vorgestellten Verfahren des Forward Model Learnings erweitern die Anwendbarkeit von Planungs- und Suchalgorithmen auf Szenarien in denen ein Zustandsübergangsmodell nicht bekannt ist. Abbildung 1 gibt einen Überblick über die in diesem Abschnitt präsentierten Methoden und stellt die strategische Position der Arbeit im Kontext anderer wissenschaftlicher Arbeiten dar.

2 Dekomposition von Forward Model Learning

Das Ziel von Forward Model Learning ist das Erlernen von Zustandsübergangsmodellen aufgrund bisheriger Interaktionen des Agenten mit seiner Umgebung. Forward Models treffen anhand des aktuellen Zustands des Systems und der Aktion des Agentens eine Vorhersage über den nächsten zu beobachtenden Zustand.




Abb. 2: Visueller Vergleich von Forward Model Architekturen [Do20]

In meiner Dissertation untersuche ich Algorithmen zum Lernen von Forward Modellen, welche mithilfe eines Suchalgorithmus verwendet werden können. Im Folgenden wird eine Unabhängigkeit der Vorhersage von vorherigen Zeitschritten angenommen. Hierdurch lässt sich das Zustandsübergangsmodell wie folgt reduzieren:

$$p(s_t \mid s_{t-1}, a_{t-1}, \dots, s_{t-m}, a_{t-m}) = p(s_t \mid s_{t-1}, a_{t-1})$$

Sind Beobachtungen von Ein- und Ausgaben eines uns unbekannten Zustandsübergangsmodells vorhanden, so können wir anhand eines überwachten Lernverfahrens ein approximatives Modell generieren. Bildet dieses den aktuellen Zustand und die Aktion des Agenten direkt auf den Folgezustand ab, sprechen wir von einem End-to-End Forward Model. Dieses Verfahren wird hauptsächlich in Kombination mit Deep Neural Networks verwendet, welche im Falle hinreichender Trainingsdaten oft in der Lage sind, sehr komplexe Zustandsübergangsmodelle zu erlernen [HS18]. Die Generierung einer ausreichenden Menge an Trainingsdaten ist jedoch zeit- und kostenaufwändig.

Aus diesem Grund werden Dekompositionstechniken genutzt um das Zustandsübergangsmodell in mehrere Komponentenmodelle zu zerlegen. Hierfür werden zunächst voneinander unabhängige Mengen von Variablen anhand einer Abhängigkeitsanalyse bestimmt [DTK18]. Bei einer vollständigen Unabhängigkeit beteiligter Zustandsvariablen kann ein Modell pro Variable erlernt werden, bzw. ein Modell für die Änderung ihres Werts bis zum nächsten Zeitschritt (differentiell):

$$\text{Komponentenmodell: } p(s_t^i \mid s_{t-1}, a_{t-1}, \dots, s_1, a_1)$$

$$\text{Differentielles Komponentenmodell: } p(s_{t-1}^i - s_t^i \mid s_{t-1}, a_{t-1}, \dots, s_1, a_1)$$

Die Prädiktion des Folgezustands ergibt sich aus der Aufteilung des Zustands in voneinander unabhängige Komponenten, der Prädiktion dieser Komponenten und der anschließenden Aggregation der Resultate. Abbildung 2 zeigt einen Vergleich des Prädiktionsablaufs zwischen End-to-End und Decomposed Forward Modellen.

3 Modellbildungsheuristiken

Um die Modellbildung zu beschleunigen kann Vorwissen über das Zustandsübergangsmodell in Form von Modellbildungsheuristiken in den Prozess einfließen. Im Folgenden werden das Local Forward Model und das Object-based Forward Model beschrieben, welche beispielhaft für die Abstraktion eines Zustandsübergangsmodells durch die Annahme von Unabhängigkeiten stehen.

3.1 Local Forward Model

Local Forward Models ähneln in ihrer Funktionsweise Convolutional Neural Networks [GBC16]. Hierbei wird der Folgezustand anhand unabhängiger Beobachtungen einzelner Informationsquellen vorhergesagt, wobei der Folgezustand lediglich vom eigenen Zustand und dem Zustand „benachbarter“ Quellen abhängt. Nachfolgend gehen wir davon aus, dass weit entfernte Informationsquellen voneinander unabhängig sind, und demnach der Folgezustand einer der Quellen jeweils nur von benachbarten Quellen abhängt. Ein solches System ist beispielsweise bei der Betrachtung von räumlichen Interaktionen aus der Vogelperspektive gegeben. Zwei Objekte oder Personen, die weit voneinander entfernt sind, können sich hierbei nicht direkt beeinflussen, wohingegen nebeneinanderliegende Objekte sich gegenseitig durch Interaktionen beeinflussen können.

Die lokale Transitionsfunktion beschreibt die Veränderung einer Zustandsvariable abhängig von dem Wert der Zustandsvariablen in ihrer Nachbarschaft:

$$fm_i : (N(S_t^{(i)}), A_t) \mapsto S_{t+1}^{(i)}$$

wobei $N(S_t^{(i)}) \subseteq \mathcal{S}$ die Menge benachbarter Zustandsvariablen der Zustandsvariable i zum Zeitpunkt t beschreibt. Gegeben einer Distanzfunktion d und einem Schwellwert ε kann die lokale Nachbarschaft einer Zustandsvariable durch die folgende Funktion bestimmt werden:

$$N(S_t^{(i)}) = \left\{ S_t^{(j)} \mid d(S_t^{(i)}, S_t^{(j)}) \leq \varepsilon, \quad j \in 1, \dots, n \right\}$$

Im Folgenden wird eine Zustandsbeschreibung auf Basis einer Matrix T verwendet, deren Zellen $T(i, j)$ den nominalen Zustand einer Zustandsvariable an der Position (i, j) angibt:

$$T = \begin{bmatrix} T(1,1) & \dots & T(1,m) \\ \vdots & \ddots & \vdots \\ T(n,1) & \dots & T(n,m) \end{bmatrix}$$

Die lokale Transitionsfunktion ergibt sich aus:

$$fm_{x,y} : (N(x,y)_t, A_t) \mapsto T(x,y)_{t+1}$$

In einer Evaluierung von Lucas et al. [Lu19] zeigen sich Local Forward Models durch wenige Beispiele in der Lage, das Regelwerk von Conway's Game of Life präzise abzubilden. Durch die häufig in Spielen verwendete Zustandsbeschreibung als Matrix bietet sich




Abb. 3: Visueller Vergleich von Modellbildungsheuristiken [Do20]

deren Modellierung durch Local Forward Modelle an. Tests mit dem Spiel Sokoban [Do19] zeigten, dass präzise Modelle anhand weniger Wiederholungen gelernt und auf unbekannte Zustände übertragen werden können.

3.2 Object-based Forward Model

Die Grundlage des Object-based Forward Models bilden nicht räumliche, sondern semantische Abhängigkeiten von Zustandsvariablen. Setzt sich der Zustand aus voneinander abgrenzbaren Entitäten ab, welchen jeweils eine Menge an Zustandsvariablen zugeordnet werden, so können diese separat von anderen Entitäten modelliert werden. Hierbei nutzt das Object-based Forward Model Vorwissen über solch separierbare Zustandsvariablengruppen, um eine entsprechende Aufteilung in voneinander unabhängige Modellkomponenten zu realisieren.

Im Folgenden gehen wir davon aus, dass der Agent über eine objekt-basierte Partitionierung der beobachtbaren Zustandsvariablen verfügt. Eine Partitionierung kann die Mengen von Sensorwerten $1, \dots, m$ beschreiben, die zu einem gemeinsamen Objekt in der Umgebung gehören, wie z. B. dem Avatar des Agenten oder eines Nicht-Spieler-Charakters.

$$\begin{aligned}
 \mathcal{S} &= (S^{(1)}, S^{(2)}, \dots, S^{(n)}) \\
 &= (\underbrace{S^{(1,1)}, \dots, S^{(1,i)}}_{\text{Objekt 1}}, \dots, \underbrace{S^{(m,1)}, \dots, S^{(m,k)}}_{\text{Objekt m}})
 \end{aligned}$$

Für jedes Objekt approximieren wir ein Objektmodell fm_i , welches dessen aktuellen Zustand und die Aktion des Agenten auf den nächsten Zustand abbildet:

$$fm_i : \left((S_t^{(i,1)}, \dots, S_t^{(i,k)}), A_t \right) \mapsto (S_{t+1}^{(i,1)}, \dots, S_{t+1}^{(i,k)})$$

Sind die Attribute eines Objekts zudem voneinander unabhängig, kann ein Decomposed Forward Model verwendet werden, um das Objektmodell des Objekts zu modellieren.

$$fm_{i,j} : \left((S_t^{(i,1)}, \dots, S_t^{(i,k)}), A_t \right) \mapsto S_{t+1}^{(i,j)}$$

Dies führt zu einer mehrstufigen Abstraktion des Systems. Um den nächsten Zustand vorherzusagen, wird der aktuelle Zustand zunächst partitioniert und in Folge dessen jedes Objektmodell aufgerufen. Die Ausgaben dieser werden nachfolgend aggregiert, um den vorhergesagten Zustand zu erhalten. Sollten unterschiedliche Objekte gleiche Verhaltensweisen aufzeigen, so können deren gelernten Modelle zusammengeführt werden (vgl. Abbildung 3).

$$\begin{aligned} fm(S_t, A_t) &= (fm_1(S_t, A_t), \dots, fm_n(S_t, A_t)) \\ &= ((fm_{1,1}((S_t^{(1,1)}, \dots, S_t^{(1,k)}), A_t), \dots, fm_{m,k}((S_t^{(m,1)}, \dots, S_t^{(m,k')}), A_t))) \\ &= (S_{t+1}^{(1)}, S_{t+1}^{(2)}, \dots, S_{t+1}^{(n)}) = S_{t+1} \end{aligned}$$

4 Predictive State Determinization

In der bisherigen Modellbildung wurde von einem vollständig beobachtbaren Zustand des Systems ausgegangen. Dies ist jedoch in vielen Spielen nicht gegeben. Das populäre Genre der Kartenspiele, in welchen zumeist die Karten der Gegenspieler nicht eingesehen werden können, ist nur eines von vielen Beispielsystemen in welchen der Agent aus unvollständigen Informationen den Zustand des Systems ermitteln muss.

Diese Problematik wurde anhand des digitalen Kartenspiels Hearthstone untersucht, welches durch seine mehr als 2000 verschiedenen Karten mit teils einzigartigen Effekten ein äußerst komplexes Spiel darstellt. Hierbei wählt jeder Spieler 30 Karten um ein individuelles Deck zu konstruieren. Aufgrund von häufig auftretenden Kartenkombinationen ist es möglich, die Karten des gegnerischen Decks anhand der ersten Spielrunden zu erraten. Zum effektiven Einsatz eines Suchverfahrens bildet der Agent ein Modell zur Vorhersage der restlichen Karten des Gegenspielers und somit zur Vervollständigung der Zustandsbeobachtung. Hierfür wurden zwei Modelle entwickelt, welche in den folgenden Abschnitten näher erläutert werden.

Im ersten vorgestellten Verfahren wird angenommen, dass jede vom Gegner gespielte Karte unabhängige Informationen über die nächste zu spielende Karte liefert. Hierbei wird davon ausgegangen, dass Karten, die in der Vergangenheit bereits häufig zusammen auftraten, dies auch in Zukunft tun werden. Die Idee ist durch eine Arbeit von Elie Bursztein [Bu16] motiviert und wurde im Rahmen der Dissertation um vier weitere Varianten zur Zählung gemeinsam auftretender Karten ergänzt. Hierbei wurde eine Datenbank von Decks menschlicher Spieler analysiert um die jeweiligen Häufigkeitswerte zu bestimmen. Aufgrund der Vielzahl an Karten wurde die Zählung auf Bigramme begrenzt. Dies birgt den Nachteil, dass größere Zusammenhänge der Deck-Gestaltung nicht abgebildet werden können.

Um die Art des gegnerischen Decks zu erfassen, wurde die Datenbank bestehender Decks im Rahmen eines neu entwickelten Fuzzy Multiset Clustering Verfahrens auf Deck-Archetypen

reduziert. Hierbei wird jedes Deck als Multiset beschrieben, wobei die Kombination ähnlicher Decks als Fuzzy Multiset [Ya86] beschrieben werden kann. Für ein solches wurde ein Clustering Verfahren entworfen [DSK08], welches in prototypischen Deck-Zusammenstellungen resultiert. Durch die Definition der Distanz eines Prototypens zur Menge aller vom Gegner bereits gespielten Karten ist es möglich, die Art des gegnerischen Decks abzuschätzen und die übrigen Karten des Gegners vorherzusagen [DK20c].

Beide Verfahren ermöglichen es, Vorhersagen über die gegnerischen Karten zu treffen. Da diese Abschätzung jedoch fehlerhaft sein kann, ist es nötig, diesen potentiellen Fehler auch innerhalb des Suchverfahrens abzubilden. Hierfür wurde der Ensemble-MCTS Algorithmus entwickelt [Do18], welcher einen separaten Suchlauf für jede Prädiktion durchführt und deren Ergebnisse aggregiert um eine robuste Entscheidung zu treffen.

5 Ergebnisse und Schlussfolgerungen

Die in meiner Dissertation vorgestellten Verfahren wurden anhand einer Vielzahl von Anwendungen evaluiert. Abschließend werden diese und darauf aufbauende Studien kurz vorgestellt und deren Bedeutung für das Forschungsgebiet hervorgehoben.

Die in den Abschnitten 2 und 3 vorgestellten Model Learning Verfahren wurden anhand von 30 Spielen des General Video Game AI (GVGAI) Frameworks evaluiert [Pe19]. Hierbei lernte der Agent die Spiele innerhalb von 100 Runden zu spielen ohne jegliches Vorwissen. Insofern die Unabhängigkeitsannahmen der Modellheuristiken erfüllt waren, erzielten die gelernten Modelle eine nahezu perfekte Vorhersage der Folgezustände und ermöglichten den effizienten Einsatz getesteter Suchverfahren. Die resultierenden Agenten übertrafen deutlich die zuvor besten Agenten des mit dem Frameworks assoziierten GVGAI-Wettbewerbs.

Methoden der Predictive State Determinization wurden anhand des zuvor beschriebenen Spiels Hearthstone evaluiert. Da für diese Anwendung keine vergleichbaren Studien existierten, wurde der Hearthstone AI Wettbewerb von mir ins Leben gerufen. Als Teil der IEEE Conference on Games konnten in 3 Wettbewerbsjahren insgesamt 100 Einreichungen von Wissenschaftlern aus der ganzen Welt gesammelt werden. In einem Vergleich mit den besten Einreichungen der Jahre 2018 und 2019 erzielte das von mir entwickelte Verfahren die besten Leistungen.

In Folge der Dissertation konnten die vorgestellten Methoden weiterentwickelt und auf weitere Anwendungsfelder übertragen werden. Durch den Einsatz von Active Learning [DK20a] wird der Trainingsprozess weiter beschleunigt. Die Einbindung der Modellsicherheit in den Planungsprozess führte zu robusteren Ergebnissen während des Trainings und der Evaluierung [DK20a]. Während die präsentierten Model Learning Verfahren noch auf diskrete Zustands- und Aktionsräume limitiert waren, konnte eine Erweiterung auf kontinuierliche Räume abgeleitet werden [DK20b]. Diese führte zum erfolgreichen Einsatz der vorgestellten Verfahren im Kontext einer Auswahl von Motion Control Szenarien.

Die präsentierten Verfahren stellen einen wichtigen Beitrag für Model Learning und Vorhersage-basierter Suche dar. Im Gegensatz zu populären Deep Learning Verfahren ist

das Ergebnis des Modells und der Suche interpretierbar. Durch die strukturelle Analyse von Abhängigkeiten der Ein- und Ausgabedaten können selbst komplexe Zustandsübergangsmodelle effizient repräsentiert und erlernt werden. Durch die Modellierung der Sicherheit des resultierenden Modells zeigt sich die Vorhersage-basierte Suche robust gegenüber unvorhergesehenen Zuständen des Systems und trägt damit maßgeblich zum sicheren Einsatz in der Praxis bei. Die Generalisierbarkeit des Verfahrens auf weitere Anwendungsgebiete konnte bereits anhand von Szenarien der Robotik demonstriert werden [DK20b] und wird in zukünftigen Arbeiten weiter verfolgt.

Literaturverzeichnis

- [Br12] Browne, C. B.; Powley, E.; Whitehouse, D.; Lucas, S. M.; Cowling, P. I.; Rohlfshagen, P.; Tavener, S.; Perez, D.; Samothrakis, S.; Colton, S.: A Survey of Monte Carlo Tree Search Methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [Bu16] Bursztein, Elie: I am a legend: Hacking hearthstone using statistical learning methods. In: 2016 IEEE Conference on Computational Intelligence and Games (CIG). IEEE, S. 1–8, sep 2016.
- [DK20a] Dockhorn, Alexander; Kruse, Rudolf: Balancing Exploration And Exploitation in Forward Model Learning. In: *Advances in Intelligent Systems Research and Innovation*, S. 1–20. Elsevier, 2020.
- [DK20b] Dockhorn, Alexander; Kruse, Rudolf: Forward Model Learning for Motion Control Tasks. In: 2020 IEEE 10th International Conference on Intelligent Systems (IS). IEEE, S. 1–5, 8 2020.
- [DK20c] Dockhorn, Alexander; Kruse, Rudolf: Predicting cards using a fuzzy multiset clustering of decks. *International Journal of Computational Intelligence Systems*, 13(1):1207–1217, 2020.
- [Do18] Dockhorn, Alexander; Frick, Max; Akkaya, Ünal; Kruse, Rudolf: Predicting Opponent Moves for Improving Hearthstone AI. In (Medina, Jesus; Ojeda-Aciego, Manuel; Verdégay, Jose Luis; Pelta, David A.; Cabrera, Inma P.; Bouchon-Meunier, Bernadette; Yager, Ronald R., Hrsg.): 17th International Conference on Information Processing and Management of Uncertainty in Knowledge-Based Systems, IPMU 2018. Springer International Publishing, S. 621–632, 2018.
- [Do19] Dockhorn, Alexander; Lucas, Simon M; Volz, Vanessa; Bravi, Ivan; Gaina, Raluca D; Perez-Liebana, Diego: Learning Local Forward Models on Unforgiving Games. In: 2019 IEEE Conference on Games (CoG). IEEE, London, S. 1–4, 8 2019.
- [Do20] Dockhorn, Alexander: Prediction-based Search for Autonomous Game-Playing. Dissertation, Otto von Guericke University Magdeburg, 2020.
- [DSK08] Dockhorn, Alexander; Schwensfeier, Tony; Kruse, Rudolf: Fuzzy Multiset Clustering for Metagame Analysis. In: *Proceedings of the 11th Conference of the European Society for Fuzzy Logic and Technology (EUSFLAT 2019)*. Atlantis Press, S. 536–543, 2019/08.
- [DTK18] Dockhorn, Alexander; Tippelt, Tim; Kruse, Rudolf: Model Decomposition for Forward Model Approximation. In: 2018 IEEE Symposium Series on Computational Intelligence (SSCI). IEEE, S. 1751–1757, 11 2018.

- [GBC16] Goodfellow, Ian; Bengio, Yoshua; Courville, Aaron: Deep Learning. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [GLP05] Genesereth, Michael; Love, Nathaniel; Pell, Barney: General Game Playing: Overview of the AAAI Competition. AI Magazin, 26(2):62–72, 2005.
- [GLP17] Gaina, R. D.; Lucas, S. M.; Perez-Liebana, D.: Rolling horizon evolution enhancements in general video game playing. In: 2017 IEEE Conference on Computational Intelligence and Games (CIG). S. 88–95, 2017.
- [HS18] Ha, David; Schmidhuber, Jürgen: Recurrent World Models Facilitate Policy Evolution. In (Bengio, S.; Wallach, H.; Larochelle, H.; Grauman, K.; Cesa-Bianchi, N.; Garnett, R., Hrsg.): Advances in Neural Information Processing Systems. Jgg. 31. Curran Associates, Inc., S. 2450–2462, 2018.
- [Le13] Levine, John; Congdon, Cb; Ebner, Marc; Kendall, Graham: General video game playing. Dagstuhl Follow-Ups, S. 1–7, 2013.
- [Lu19] Lucas, Simon M; Dockhorn, Alexander; Volz, Vanessa; Bamford, Chris; Gaina, Raluca D; Bravi, Ivan; Perez-Liebana, Diego; Mostaghim, Sanaz; Kruse, Rudolf: A Local Approach to Forward Model Learning: Results on the Game of Life Game. In: 2019 IEEE Conference on Games (CoG). IEEE, S. 1–8, 8 2019.
- [Mn15] Mnih, Volodymyr; Kavukcuoglu, Koray; Silver, David; Rusu, Andrei a; Veness, Joel; Bellemare, Marc G; Graves, Alex; Riedmiller, Martin; Fidjeland, Andreas K; Ostrovski, Georg; Petersen, Stig; Beattie, Charles; Sadik, Amir; Antonoglou, Ioannis; King, Helen; Kumaran, Dharshan; Wierstra, Daan; Legg, Shane; Hassabis, Demis: Human-level control through deep reinforcement learning. Nature, 518(7540):529–533, 2 2015.
- [Pe19] Perez-Liebana, Diego; Lucas, Simon M.; Gaina, Raluca D.; Togelius, Julian; Khalifa, Ahmed; Liu, Jialin: General Video Game Artificial Intelligence, Jgg. 3. Morgan & Claypool Publishers, 2019. <https://gaigresearch.github.io/gvgaibook/>.
- [SB18] Sutton, Richard S.; Barto, Andrew G.: Reinforcement Learning. The MIT Press, Cambridge, 2. Auflage, 2018.
- [Ya86] Yager, Ronald R.: On the Theory of Bags. International Journal of General Systems, 13(1):23–37, nov 1986.



Alexander Dockhorn ist Postdoctoral Research Associate an der Queen Mary University of London. Seinen Dokortitel erhielt er an der Otto-von-Guericke-Universität in Magdeburg. In seiner Forschung untersucht er die Fähigkeiten von prädiktionsbasierten Suchagenten in Spielen mit einem besonderen Interesse zur Modellierung von Unsicherheiten. Als Mitglied des Institute of Electrical and Electronics Engineers (IEEE) beteiligt er sich aktiv an der Mitgestaltung der Forschungslandschaft und fungiert als Vorsitzender des IEEE CIS Competitions Sub-Committees, sowie als Mitglied zahlreicher weiterer Komitees. Seit 2017 organisiert er den Hearthstone-KI-Wettbewerb, um die Vergleichbarkeit von KI-Agenten in Kartenspielen zu fördern. Eine vollständige Liste seiner Projekte und Veröffentlichungen finden Sie auf seiner Webseite: <https://adockhorn.github.io/>