

Unsicheres und unscharfes Wissen

1 Einleitung

Wissensbasierte Systeme sind Programme, die auf der Grundlage von Wissen über bestimmte Anwendungsbereiche Schlussfolgerungen ziehen können und so einem Benutzer helfen, ein Problem zu lösen oder eine Entscheidung zu treffen. Solche Systeme lassen sich kaum auf die Verarbeitung völlig präzisen und sicheren Wissens beschränken. Denn schon eine Aussage wie „Sabine hat wahrscheinlich Grippe.“ ist unsicher, und eine Aussage wie „Peter ist zu Hause.“ ist unscharf, da sein genauer Aufenthaltsort (Wohnzimmer, Bad, Küche usw.) unbestimmt bleibt. Tatsächlich sind fast alle Aussagen des täglichen Lebens unsicher, unscharf oder beides.

Dennoch sind solche Aussagen nicht unbrauchbar: Menschen können aus ihnen ohne große Schwierigkeiten Schlüsse ziehen; wenn auch, der Natur dieser Aussagen geschuldet, keine präzisen und absolut sicheren, aber doch nützliche und praktisch brauchbare. Ein Arzt wird z.B. bestimmte Krankheiten ausschließen, wenn er erfährt, dass ein Patient kein Fieber hat, auch wenn er die genaue Körpertemperatur nicht (oder nicht sicher) kennt.

Folglich müssen, wenn wissensbasierte Systeme eine echte, in der Praxis brauchbare Unterstützung des Menschen sein sollen, Methoden zur Darstellung von unsicherem und unscharfem Wissen in einem Rechner und Methoden zum automatischen Schlussfolgern mit solchem Wissen bereitgestellt werden. Eine (kleine) Auswahl solcher Methoden wird in diesem Kapitel vorgestellt.

1.1 Eigenschaften von Wissen: Impräzision, Unsicherheit und Unschärfe

In diesem Kapitel wird *Wissen* aufgefasst als eine Zuordnung von bestimmten Werten, etwa von Wahrheitswerten, Wahrscheinlichkeiten, Possibilitätsgraden o.ä., zu Aussagen, Ereignissen, Zuständen etc. Die Unterscheidung von Aussagen, Ereignissen, Zuständen etc. werden wir aber fallenlassen, denn soll Wissen der intersubjektiven Prüfung und einer sorgfältigen Analyse zugänglich gemacht werden, so muss es in einer Sprache formuliert werden. Man kann sich daher auf Aussagen beschränken, die dann mit den Ereignissen oder Zuständen, die

sie beschreiben, identifiziert werden. Man beachte aber, dass Kalküle, die zur Darstellung von Wissen verwendet werden, oft eigene, kalkülspezifische Begriffe nutzen. So spricht man etwa üblicherweise von der Wahrscheinlichkeit von Ereignissen.

Wir untersuchen nun drei Eigenschaften, die Wissen haben kann: *Impräzision*, *Unsicherheit* und *Unschärfe*. Während sich Impräzision noch mit klassischer Logik behandeln lässt, braucht man zur Darstellung von Unsicherheit und Unschärfe andere Kalküle, da man über einfache Wahrheitswerte hinausgehen muss.

Impräzision Aussagen wie „Der Ball ist grün oder blau oder türkis.“ oder „Die Geschwindigkeit des Autos lag zwischen 50 und 60 km/h.“ nennen wir *impräzise* (englisch: imprecise). Sie sind impräzise, weil sie nicht nur einen Wert einer Eigenschaft (hier: Farbe bzw. Geschwindigkeit) angeben, sondern eine *Menge von Alternativen*, entweder durch Aufzählung oder durch eine Intervallangabe. Im Gegensatz dazu nennen wir Aussagen, die nur einen Wert für eine Eigenschaft angeben, *präzise*. Ein Beispiel einer präzisen Aussage ist „Der Patient hat 39.3° Fieber.“¹

Es ist klar, dass sich Impräzision mit den Mitteln der klassischen symbolischen Logik behandeln lässt: Endliche Mengen von Alternativen kann man einfach durch Disjunktionen darstellen, die die Alternativen aufzählen, und Intervalle können beschrieben werden, indem man Vergleichsprädikate $\geq$ und/oder $\leq$ einführt.

Unsicherheit Oft setzen wir implizit voraus, dass Aussagen *sicher* sind, d.h., dass alle Alternativen, die nicht genannt sind, definitiv ausgeschlossen werden können. So nimmt man etwa an, dass in den obigen Beispielen der Ball bestimmt nicht rot ist und das Auto auf jeden Fall schneller als 40 km/h fuhr. Falls solche, in einer Aussage nicht genannten Alternativen *nicht* ausgeschlossen werden können, nennen wir die Aussage *unsicher*. Denn sie könnte ja falsch sein, da es möglich ist, dass eine der nicht genannten Alternativen die wahre Situation beschreibt. Man beachte, dass sowohl präzise als auch impräzise Aussagen unsicher sein können. Was eine Aussage sicher oder unsicher macht, ist nicht die Anzahl der (genannten) Alternativen, sondern ob alle möglichen Alternativen in ihr genannt sind.

Beschränkt man sich darauf, Aussagen als sicher oder unsicher zu *kennzeichnen*, kommt man noch mit den Mitteln der Logik aus: In der *Modallogik* werden zu diesem Zweck die *Modalitäten* „notwendig“ und „möglich“ eingeführt. Dies reicht

¹ Man könnte einwenden, dass es in dieser Aussage so etwas wie implizite Impräzision gibt, da die Temperatur nur mit endlicher Genauigkeit angegeben ist; d.h., eigentlich sind alle Temperaturen zwischen 39.25° und 39.35° möglich. Wir vernachlässigen dies hier.

jedoch nicht mehr aus, wenn man zwischen mehreren unsicheren Aussagen zu entscheiden hat. Dann braucht man Kalküle, in denen sich mindestens *Präferenzen* zwischen unsicheren Aussagen ausdrücken oder sich sogar die Verlässlichkeiten von Aussagen durch Sicherheits- oder Vertrauensgrade *quantifizieren* lassen.

Unschärfe Die meisten Begriffe der Alltagssprache sind *unscharf*: Wenn wir sagen, Peter sei *groß* oder an einem Sommertag sei es *heiß*, dann meinen wir keine bestimmte Körpergröße und keine bestimmte Temperatur, ja nicht einmal ein Intervall wie bei impräzisen Aussagen. Die Bereiche der Körpergrößen und Temperaturen, die als *groß* bzw. *heiß* bezeichnet werden können, sind nicht scharf begrenzt. Zwar gibt es Werte der Körpergröße, die sicher als *groß* bezeichnet werden können, z.B. 220 cm, und solche, die sicher nicht als *groß* bezeichnet werden können, z.B. 140 cm. Genauso gibt es Temperaturen, die sicher *heiß* sind, z.B. 35°C, und solche, die es sicher nicht sind, z.B. 5°C. Doch zwischen diesen Körpergrößen bzw. Temperaturen, für die eindeutig und allgemein anerkannt entschieden werden kann, ob der Begriff anwendbar ist oder nicht, liegt eine *Penumbra* (lat. für *Halbschatten*) von Werten, die nicht eindeutig zugeordnet werden können.

Zwar kann man stets eine Penumbra beseitigen, indem man willkürlich eine scharfe Grenze zieht, doch entspricht eine solche scharfe Grenze meist nicht mehr dem natürlichen Verständnis sprachlicher Begriffe [51](Nr. 76). Unscharfe Aussagen sind auch nicht notwendig Aussagen minderer Qualität und schon gar nicht nutzlos, denn in der Praxis können sie völlig hinreichend sein, während eine erzwungene Genauigkeit ins Leere laufen und sinnlos sein kann [51](Nr. 88). Ein impräzises Datum kann man als spezielles unscharfes Datum auffassen. Wissen kann gleichzeitig Unsicherheit und Unschärfe beinhalten, wenn z.B. unscharfe Daten mit einem Zufallsprozess generiert werden.

1.2 Modellierung von Schlussfolgerungsprozessen

Die wesentliche Eigenschaft des Schlussfolgerns ist, dass ein bestimmter Typ von Wissen — Wissen über Wahrheit, Wahrscheinlichkeit, (Grad der) Möglichkeit o.ä. — von gegebenen Aussagen, Ereignissen, Zuständen etc. auf andere Aussagen, Ereignisse, Zustände etc. übertragen wird. Z.B. wird in einem (vor allem deduktiven, aber auch induktiven oder reduktiven) logischen Schluss Wissen über die Wahrheit der Prämissen auf die Konklusion übertragen; in der Wahrscheinlichkeitstheorie geht die Wahrscheinlichkeit eines Ereignisses in die Berechnung der Wahrscheinlichkeit anderer, in Beziehung stehender Ereignisse ein und wird so in gewisser Weise auf diese anderen Ereignisse übertragen etc.

Damit eine solche Übertragung möglich ist, sind drei Dinge erforderlich. Erstens: ein Ausgangswissen, auf das man sich stützen kann – zum Beispiel das Wissen, dass eine bestimmte Aussage wahr ist. Zweitens: ein Wissen, das einen Weg für die Übertragung eröffnet – etwa eine Implikation, bei der die gegebene Aussage das Antezedens bildet. Und drittens: ein Mechanismus, der es erlaubt, diesem Weg zu folgen – zum Beispiel die Schlussregel des Modus Ponens, mit der sich die Wahrheit des Konsequens einer Implikation erschließen lässt, wenn das Antezedens bekannt ist. Nur wenn alle drei gegeben sind und zusammenpassen, kann eine Schlussfolgerung gezogen werden. Natürlich muss die Übertragung nicht immer direkt sein. In der klassischen Logik kann man z.B. Argumente verketteten, indem man die Konklusion eines Argumentes zur Prämisse eines anderen macht. Bisweilen sind mehrere solcher Schritte nötig, um eine gewünschte Konklusion abzuleiten. Ähnlich ist es in der Wahrscheinlichkeitstheorie.

Aus dieser Beschreibung können wir ablesen, was die wesentlichen Probleme der Modellierung von Schlussfolgerungsprozessen sind: Sie bestehen darin, die Pfade aufzufinden, auf denen Wissen übertragen werden kann, und geeignete Mechanismen bereitzustellen, mit denen diese Pfade verfolgt werden können. Im Gegensatz dazu ist das Wissen, von dem man ausgeht, i.A. direkt verfügbar, z.B. als Ergebnis von Beobachtungen (auch wenn man die Probleme der Feststellung von Tatsachen nicht unterschätzen sollte) oder wissenschaftlicher Theoriebildung.

Sicher ist die klassische Logik [5, 37, 40, 42] der bekannteste Ansatz, um diese Probleme zu lösen. Sie ermöglicht, Wissen über einen bestimmten Anwendungsbereich als Menge von Aussagen darzustellen, die nur wenige atomare Aussagen oder Prädikate enthält. Weiter stellt sie einfache Schlussregeln bereit, die die Pfade sind, auf denen durch Beobachtungen gewonnenes Wissen auf andere, nicht direkt beobachtbare Aussagen übertragen werden kann. Alle Folgerungen lassen sich mit Hilfe der Schlussregeln ableiten, auch wenn dies eine mitunter aufwendige Suche nach geeigneten Argumenten erfordert. Es liegt nahe, die in der Logik bereits geleistete Arbeit zu nutzen, indem man nach einer Erweiterung auf unsichere Aussagen sucht. In dieser Erweiterung arbeitet man statt mit Wahrheitswerten *wahr* und *falsch*, die mit 1 und 0 oder mit 1 und -1 identifiziert werden können, mit recht einfachen *Sicherheitsfaktoren*, um unsicheres Wissen zu behandeln. Dieser Ansatz der Sicherheitsfaktoren wurde im frühen Expertensystem MYCIN verwendet, um unsichere Regeln zu modellieren [4].

Die Analyse dieses Ansatzes zeigt jedoch, dass er sehr starke, in der Praxis oft nicht erfüllte Unabhängigkeitsannahmen macht. Insbesondere kann die Einschätzung einer Konklusion von der Reihenfolge der Schlussfolgerungen abhängen und es kann, wenn ein beobachtetes Faktum über mehrere Implikationsketten auf die gleiche Konklusion führt, zu einer fehlerhaften Einschätzung der Sicherheit dieser Konklusion kommen. Man beachte dabei, dass die Unabhängigkeitsannahmen

in der Struktur der zweiwertigen Logik liegen. Bei einer Beschränkung auf die Sicherheitsfaktoren 0 und 1 bzw. -1 und 1 (für falsch und wahr) sind sie notwendigerweise erfüllt. Erst wenn man Zwischenwerte zulässt, können sie sich negativ auswirken. Dann jedoch können sie, wenn die implizit vorausgesetzten Unabhängigkeiten nicht gelten, zu falschen Ergebnissen führen. Ein Effekt, welcher in vielen Expertensystemen eingetreten ist.

Folglich müssen eventuell vorhandene Abhängigkeiten explizit erfasst und berücksichtigt werden. Da die Aussagen, die zum Schlussfolgern über einen bestimmten Anwendungsbereich benutzt werden, meist die Form von Implikationen haben (oder zu Implikationen äquivalent sind), bietet es sich an, sie dazu durch einem (gerichteten) Graphen darzustellen. Dieser Graph gibt die Argumentketten wieder, die aus den Implikationen und beobachteten Fakten gebildet werden können, indem die Terme des Antezedens einer Implikation mit dem Konsequens durch gerichtete Kanten verbunden werden. Aus einem solchen Graphen lässt sich dann leicht ablesen, welche Aussagen auf welche Schlussfolgerungen Einfluss haben und welche Abhängigkeiten folglich bestehen. Außerdem zeigt er direkt die möglichen Übertragungswege für aus Beobachtungen gewonnenes Wissen und hilft daher auch, den Schlussfolgerungsprozess effizienter zu machen.

Mit dieser Überlegung haben wir bereits einen ersten Schritt in Richtung auf *probabilistische Schlussfolgerungsnetze* getan, die wir in Abschnitt 3 betrachten. Die grundlegende Idee dieser Netze, die auch *probabilistische graphische Modelle* genannt werden (Graphen im Sinne der Graphentheorie), ist es, die Pfade, auf denen (probabilistisches) Wissen übertragen wird, in Form eines (gerichteten oder ungerichteten) Graphen darzustellen. Eine solche Darstellung kann gewöhnlich erreicht werden, wenn es gelingt, das Wissen über den betrachteten Anwendungsbereich geeignet zu zerlegen — ähnlich wie man es in der Logik in eine Menge von Implikationen zerlegt. Der Graph beschreibt diese Zerlegung und gibt an, auf welchen Wegen Informationen weitergegeben werden müssen. Der Unterschied besteht im Wesentlichen darin, dass nicht eine Menge von Implikationen, sondern eine Familie von (bedingten oder Rand-) Verteilungen dargestellt wird, die i.A. informationsreicher sind als einfache Implikationen.

Bei unscharfem Wissen, also etwa unscharfen Implikationen oder (Handlungs-) Regeln, stoßen wir auf andere Probleme. Schon wegen ihrer Unschärfe, aber auch wegen ihrer Anwendungsbereiche, können unscharfe Regeln meist als sicher angenommen werden. Da sie jedoch unscharf formuliert sind, steht bei gegebenen Beobachtungen oft in Zweifel, ob sie angewandt werden können, nämlich dann, wenn die beobachteten Werte in den Penumbrae der im Antezedens auftretenden unscharfen Begriffe liegen. Auf welche konkreten Fälle kann die Regel „Wenn etwas *sehr groß* ist, dann ist es auch *sehr schwer*.“ angewendet werden? Noch schwieriger wird es, wenn es mehrere Regeln gibt, die angewendet werden können,

von denen jedoch keine mit Sicherheit anwendbar ist. In diesem Fall geht es nicht darum, durch den Schlussfolgerungsmechanismus die Sicherheit der Konklusion zu bestimmen, sondern darum, zwischen den unscharfen Regeln geeignet zu interpolieren, um eine passende Konklusion zu bestimmen. Wir können auch sagen, die unscharfen Regeln gäben nicht, wie in der Logik, Übertragungswege an, sondern eine unscharfe Beschreibung eines Geländes, in dem wir einen Weg erst auffinden müssen.

Z.B. könnte ein Mensch die Regelung eines technischen Prozesses so beschreiben: Wenn die Temperatur *mittel* und der Druck *hoch* ist, darf das Ventil nur wenig geöffnet werden. Wenn aber sowohl Druck als auch Temperatur *niedrig* sind, muss das Ventil *weit* geöffnet werden. Was ist dann zu tun, wenn der Druck *mittel* und die Temperatur *niedrig* ist? Wie weit ist das Ventil zu öffnen? Offenbar muss hier zwischen den beiden Regeln gemittelt werden, wobei die zweite wohl stärkeres Gewicht erhalten sollte.

2 Grundlegende Konzepte

Der bekannteste Kalkül zur Behandlung von Unsicherheit ist zweifellos die Wahrscheinlichkeitstheorie, deren Grundbegriffe wir in Abschnitt 2.1 kurz rekapitulieren. Eine Methode, um mit Unschärfe umzugehen, sind Fuzzy-Mengen und Fuzzy-Regelsysteme, die wir in Abschnitt 2.2 kurz betrachten.

2.1 Unsicherheit: Wahrscheinlichkeit

Die Wahrscheinlichkeitstheorie beschäftigt sich mit *zufälligen Ereignissen*. Bei solchen Ereignissen ist zwar bekannt, welche Ereignisse überhaupt eintreten können, nicht jedoch, welches der möglichen Ereignisse tatsächlich eintreten wird (das Eintreten der (einzelnen) Ereignisse ist also unsicher). Beispiele sind das Werfen einer Münze oder eines Würfels. In der Wahrscheinlichkeitstheorie wird einem zufälligen Ereignis A ein Zahlenwert $P(A)$ — genannt Wahrscheinlichkeit — zugeschrieben. Diese Größe soll die Chance oder die Tendenz des Eintretens des Ereignisses beschreiben und so die Unsicherheit des Ereignisses quantifizieren.

Intuitive Vorstellungen des Wahrscheinlichkeitsbegriffs beruhen z.B. auf der Bestimmung des Verhältnisses der Anzahl der günstigen Ereignisse zur Gesamtzahl der unvereinbaren, gleichmöglichen Ereignisse („klassischer“ Wahrscheinlichkeitsbegriff) oder der relativen Häufigkeit des Auftretens günstiger Ereignisse in einer langen Versuchsreihe. Die moderne Mathematik hat sich jedoch die

axiomatische Methode zu eigen gemacht, bei der von der Bedeutung der Objekte, über die man spricht, abstrahiert wird. Sie nimmt Objekte als gegeben an, die keine anderen Eigenschaften haben als ihre Identität, und untersucht lediglich die Struktur der Relationen zwischen diesen Objekten, die sich aus vorausgesetzten Axiomen ergibt.

Die Wahrscheinlichkeitstheorie wird über die Kolmogorow-Axiome aufgebaut. Unter einem Ereignis wird dabei einfach eine Menge von Elementarereignissen verstanden, die unterscheidbar sind, d.h. eine Identität haben. Eine Wahrscheinlichkeit ist dann eine Zahl, die diesem Ereignis zugeordnet wird. Formale Grundlage der Kolmogorow-Axiome sind die Begriffe Ereignisalgebra und σ -Algebra.

Definition 2.1. (Ereignisalgebra und σ -Algebra)

Sei $\mathcal{S}$ ein System von Ereignissen (Mengen) über einer Grundmenge Ω von Elementarereignissen (dem Ereignisraum). $\mathcal{S}$ heißt Ereignisalgebra genau dann, wenn gilt:

1. $\mathcal{S}$ enthält das sichere Ereignis Ω
2. Gehört A zu $\mathcal{S}$, so gehört auch das komplementäre Ereignis $\bar{A} = \Omega \setminus A$ zu $\mathcal{S}$.
3. Gehören A und B zu $\mathcal{S}$, so gehören auch die Ereignisse $A \cap B$ und $A \cup B$ zu $\mathcal{S}$.

Bei einer σ -Algebra ist stattdessen die folgende, allgemeinere Bedingung erfüllt:

- 3'. Gehört für alle $n \in \mathbb{N}$ das Ereignis A_n zu $\mathcal{S}$, dann gehören auch die Ereignisse $\bigcup_{n=1}^{\infty} A_n$ und $\bigcap_{n=1}^{\infty} A_n$ zu $\mathcal{S}$.

Die leere Menge gehört immer zu einer σ -Algebra und wird als das unmögliche Ereignis bezeichnet.

Definition 2.2. (Kolmogorow-Axiome)

Gegeben sei eine Ereignisalgebra $\mathcal{S}$ über einem endlichen Ereignisraum Ω .

1. Die Wahrscheinlichkeit $P(A)$ eines Ereignisses $A \in \mathcal{S}$ ist eine eindeutig bestimmte, nicht-negative Zahl, die höchstens 1 sein kann, d.h., $0 \leq P(A) \leq 1$.
2. Das sichere Ereignis Ω besitzt die Wahrscheinlichkeit 1, d.h. $P(\Omega) = 1$.
3. (Additionsaxiom) Für zwei unvereinbare (unverträgliche) Ereignisse A und B (also mit $A \cap B = \emptyset$) gilt $P(A \cup B) = P(A) + P(B)$.

Bei Ereignisräumen Ω , die unendlich viele Elemente enthalten, muss $\mathcal{S}$ eine σ -Algebra sein und Axiom 3 ersetzt werden durch:

- 3'. (erweitertes Additionsaxiom) Sind $A_1, A_2, \dots$ abzählbar unendlich viele, paarweise disjunkte Ereignisse (also mit $\forall i, j : i \neq j \Rightarrow A_i \cap A_j = \emptyset$), so gilt $P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n)$.

Die Zuordnung $A \rightarrow P(A)$ lässt sich also als eine auf einer Ereignisalgebra definierte Funktion mit bestimmten Eigenschaften sehen. Beispielsweise lässt sich

aus der Verknüpfung von Axiom 2 und 3 folgern, dass die leere Menge $\emptyset$, welche das komplementäre Ereignis des sicheren Ereignisses Ω ist, eine Wahrscheinlichkeit von $P(\emptyset) = 0$ besitzt. Das Kolmogorowsche Axiomensystem gestattet es, die Wahrscheinlichkeitstheorie als Teil der Maßtheorie aufzubauen und die Wahrscheinlichkeit als nichtnegative normierte additive Mengenfunktion, d.h. als Maß zu interpretieren.

Zu den drei üblichen Deutungen der Wahrscheinlichkeitstheorie — *logisch*, *empirisch* (oder *frequentistisch*) und *subjektiv* (oder *personalistisch*) — und den damit verbundenen semantischen Problemen siehe z.B. [41, 49].

Oft ist die Wahrscheinlichkeit eines Ereignisses A zu bestimmen, wenn bereits bekannt ist, dass ein Ereignis B eingetreten ist.

Definition 2.3. Seien A und B zwei beliebige Ereignisse mit $P(B) > 0$. Dann heißt $P(A | B) = \frac{P(A \cap B)}{P(B)}$ die bedingte Wahrscheinlichkeit von A unter (der Bedingung) B bzw. gegeben (die Bedingung) B .

Eine bedingte Wahrscheinlichkeit hat alle Eigenschaften einer Wahrscheinlichkeit, d.h., sie erfüllt die Kolmogorow-Axiome. Damit gilt:

Satz 2.1. Für ein fest gewähltes Ereignis B mit $P(B) > 0$ ist die durch $P_B(A) = P(A|B)$ erklärte Funktion P_B eine Wahrscheinlichkeit, die $P_B(\bar{B}) = 0$ erfüllt.

Die bedingte Wahrscheinlichkeit führt zur (stochastischen) Unabhängigkeit:

Definition 2.4. Sei B ein Ereignis mit $0 < P(B) < 1$. Dann heißt das Ereignis A (stochastisch) unabhängig von B , $P(A | B) = P(A | \bar{B})$.

Hierzu sind die folgenden, meist angenehmeren Beziehungen äquivalent:

Satz 2.2. Ereignis A ist von Ereignis B mit $0 < P(B) < 1$ genau dann (stochastisch) unabhängig, wenn $P(A | B) = P(A)$ oder wenn $P(A \cap B) = P(A) \cdot P(B)$.

Man beachte, dass die (stochastische) Unabhängigkeit symmetrisch ist: Ist A (stochastisch) unabhängig von B , so ist auch B (stochastisch) unabhängig von A .

Im folgenden geben wir einige wichtige Sätze der Wahrscheinlichkeitstheorie an, die wir im weiteren Verlauf dieses Kapitels brauchen werden.

Satz 2.3. Für beliebige Ereignisse A und B gilt $P(A \cap B) = P(A | B) \cdot P(B)$.

Dieser Satz, oft *Produktsatz* oder *Multiplikationssatz* genannt, folgt unmittelbar aus der Definition der bedingten Wahrscheinlichkeit unter Hinzunahme der

offensichtlichen Beziehung $P(A \cap B) = 0$, wenn $P(B) = 0$. Durch einfache Induktion über die Zahl der Ereignisse erhält man die Verallgemeinerung für n Ereignisse, auch *Kettenregel* genannt: $P(\bigcap_{i=1}^n A_i) = \prod_{i=1}^n P(A_i \mid \bigcap_{k=1}^{i-1} A_k)$.

Oft hat man es mit Situationen zu tun, in denen die Wahrscheinlichkeit von disjunkten, zusammen den ganzen Ereignisraum abdeckenden Ereignissen A_i , sowie die bedingten Wahrscheinlichkeiten eines weiteren Ereignisses B unter den A_i bekannt sind. Gesucht ist die Gesamtwahrscheinlichkeit für das Ereignis B .

Definition 2.5. n Ereignisse $A_1, \dots, A_n$ bilden eine vollständige Ereignisdisjunktion, wenn $\forall 1 \leq i, k \leq n, i \neq k : A_i \cap A_k = \emptyset$ und $A_1 \cup \dots \cup A_n = \Omega$ gelten.

Satz 2.4. (Satz über die vollständige Wahrscheinlichkeit)

Sei $A_1, \dots, A_n$ eine vollständige Ereignisdisjunktion mit $\forall 1 \leq i \leq n : P(A_i) > 0$ (und, wie aus den Kolmogorow Axiomen folgt, $\sum_{i=1}^n P(A_i) = 1$). Dann gilt für die Wahrscheinlichkeit eines beliebigen Ereignisses B : $P(B) = \sum_{i=1}^n P(B \mid A_i) \cdot P(A_i)$.

Diesen Satz erhält man, indem man den Produktsatz auf $P(B) = P(B \cap \Omega) = P(B \cap \bigcup_{i=1}^n A_i) = P(\bigcup_{i=1}^n (B \cap A_i)) = \sum_{i=1}^n P(B \cap A_i)$ anwendet.

Mit Hilfe dieses Satzes lässt sich leicht der wichtige Bayessche Satz ableiten (nach Thomas Bayes, 1702–1761, obwohl die heute übliche Form erst von Pierre-Simon Laplace, 1749–1827, angegeben wurde). Dazu muss man sich nur klar machen, dass sich der Produktsatz auf das gleichzeitige Eintreten zweier Ereignisse A und B in zweierlei Weise anwenden lässt: $P(A \cap B) = P(A \mid B) \cdot P(B) = P(B \mid A) \cdot P(A)$. Dies führt nach Division durch $P(B)$, das dazu als positiv vorausgesetzt werden muss, zum ersten Teil des Bayesschen Satzes. Die Anwendung des Satzes über die vollständige Wahrscheinlichkeit auf den Nenner liefert dann den zweiten Teil.

Satz 2.5. (Bayesscher Satz/Bayessche Formel)

Für eine vollständige Ereignisdisjunktion $A_1, \dots, A_n$ mit $\forall 1 \leq i \leq n : P(A_i) > 0$ und jedes Ereignis B mit $P(B) > 0$ gilt der Bayessche Satz:

$$P(A_k \mid B) = \frac{P(B \mid A_k) \cdot P(A_k)}{P(B)} = \frac{P(B \mid A_k) \cdot P(A_k)}{\sum_{i=1}^n P(B \mid A_i) \cdot P(A_i)}.$$

Diese Formel heißt auch die Formel über die Wahrscheinlichkeit von Hypothesen.

2.2 Unschärfe: Fuzzy-Mengen und Fuzzy-Logik

Die Fuzzy-Mengentheorie bzw. die Fuzzy-Logik [52] sind die vorherrschenden Ansätze zur Behandlung von Unschärfe und Vagheit. Mit diesen Ansätzen versucht man einige der Probleme, die sich aus der Unschärfe sprachlicher Ausdrücke ergeben, dadurch zu lösen, dass man die Begriffe der Zugehörigkeit zu einer Menge bzw. des Wahrheitswertes „fuzzifiziert“, d.h., statt nur *ist Element* und *ist nicht Element* bzw. *wahr* und *falsch* Grade der Zugehörigkeit bzw. Wahrheit oder Möglichkeit einführt.

Eine typische Motivation liefert das klassische *Sorites-Paradoxon*: „Wieviel Körner machen einen Haufen?“² Dieses Paradoxon soll von Eubulides von Milet (4. Jahrhundert v. Chr.) aufgebracht worden sein. Ausgehend von den (*prima facie* wahren) Aussagen „Eine Ansammlung von 10^9 Sandkörnern ist ein Sandhaufen.“ und „Wenn man von einem Sandhaufen ein Sandkorn wegnimmt, dann bleibt ein Sandhaufen übrig.“ kann man eine Schlusskette konstruieren, an deren Ende die (offensichtlich falschen) Aussagen erschlossen werden, dass Ansammlungen von drei, zwei, einem, ja sogar gar keinem Sandkorn Sandhaufen sind.

Der Ausgangspunkt, dass eine Milliarde Sandkörner ein Sandhaufen sind, ist sicherlich richtig, und wir können keinen *einzelnen* Schluss identifizieren, der zu einer falschen Schlussfolgerung führt. Es gibt keine scharf bestimmte Anzahl von Sandkörnern, die noch einen Sandhaufen bilden, während eine Ansammlung mit einem Sandkorn weniger kein Sandhaufen mehr ist. Man wird vielmehr sagen müssen, dass die Konklusionen „allmählich“ falsch werden, und zwar während wir uns schließend durch die Penumbra des Begriffs „Sandhaufen“ bewegen.

Es liegt nahe, dieses „allmähliche“ Falschwerden dadurch zu modellieren, dass man neben *wahr* und *falsch* Zwischenwerte, also *Grade der Wahrheit*, einführt. Allgemein kann man mehrwertige Logiken einführen [15, 28]. In der Penumbra des Begriffs „Sandhaufen“ wird der Wahrheitsgrad dann mit jedem Schluss, d.h. mit jedem Sandkorn, das entfernt wird, ein bisschen kleiner, bis er schließlich den Wert *falsch* erreicht. Genauso können wir mit dem Begriff der Zugehörigkeit zu einer Menge verfahren, der in der klassischen Mengenlehre auch nur zweiwertig ist: Entweder ein Element gehört zu einer Menge oder es gehört nicht dazu. Da sich jedoch die Ansammlungen von Sandkörnern, die unter den Begriff des Sandhaufens fallen, nicht scharf von jenen trennen lassen, die nicht unter ihn fallen, erscheint es sinnvoll, für Ansammlungen von Sandkörnern, die in der Penumbra des Begriffs „Sandhaufen“ liegen, *Grade der Zugehörigkeit* einzuführen.

² Der Name dieses Paradoxons leitet sich ab von griech. *σωρος* (soros), d.h. „Haufen“. Das Paradoxon hieß ursprünglich *σωρίτης* (sorites), d.h. „Häufelnder“. Manchmal ergänzte man noch *λόγος* (logos) oder *συλλογισμός* (syllogismos) was dann „Haufenschluss“ ergibt.

Diese Zugehörigkeitsgrade sollten um so höher sein, je mehr Sandkörner die Ansammlung enthält.

Formal lässt sich eine Fuzzy-Menge über die *Indikatorfunktion* einer Menge einführen. Diese Funktion ordnet den Elementen einer gegebenen Grundmenge, die in der zu beschreibenden Menge enthalten sind, eine 1, allen anderen eine 0 zu und zeigt so an (lat. *indicare*: anzeigen), welche Elemente enthalten sind.

Definition 2.6. Sei U eine Menge und $X \subseteq U$. Die Indikatorfunktion von X bzgl. U ist die Funktion $I_X : U \rightarrow \{0, 1\}$, $u \mapsto 1$, falls $u \in X$, und $u \mapsto 0$ sonst.

Indem man außer 0 und 1 auch Zwischenwerte zulässt, erhält man eine *Fuzzy-Menge*.

Definition 2.7. (Fuzzy-Menge)

Eine Fuzzy-Menge über einer Menge U ist eine Funktion $\mu : U \rightarrow [0, 1]$.

Ein typisches Beispiel für eine Fuzzy-Menge sind die sprachlichen Prädikate „jung“ und „alt“. Während in der klassischen Mengenlehre eine Person entweder jung ist oder nicht, erlaubt die Fuzzy-Menge eine graduelle Zugehörigkeit. So können die exemplarischen Fuzzy-Mengen

$$\mu_{\text{jung}}(x) = \begin{cases} 1, & \text{wenn } x \leq 20 \\ \frac{30-x}{10}, & \text{wenn } 20 < x < 40 \\ 0, & \text{wenn } x \geq 30 \end{cases} \quad \mu_{\text{alt}}(x) = \begin{cases} 0, & \text{wenn } x \leq 50 \\ \frac{x-50}{20}, & \text{wenn } 50 < x < 70 \\ 1, & \text{wenn } x \geq 70 \end{cases}$$

genutzt werden, um einem gegebenen Alter einen Zugehörigkeitsgrad zuzuweisen. Hierbei ergeben sich für ein Alter von 35 Jahren die Werte $\mu_{\text{jung}}(35) = 0.25$ und $\mu_{\text{alt}}(35) = 0.125$. Analog zur Wahrscheinlichkeit ist die Deutung eines Zugehörigkeitsgrades ein komplexes semantisches Problem. Einen Überblick über verschiedene Ansätze, einschließlich der *Possibilitätstheorie*, gibt z.B. [3].

Operationen auf Fuzzy-Mengen werden in Analogie zu den Mengenoperationen Schnitt, Vereinigung und Komplementbildung eingeführt. Bedingung ist stets, dass die Operationen übereinstimmen, wenn man sich auf Indikatorfunktionen beschränkt. Weiter wird festgelegt, dass die Operationen elementweise auszuführen sind; außerdem sollten Assoziativität und Kommutativität gelten.

Diese Bedingungen legen die Operationen jedoch noch nicht eindeutig fest. Daher betrachtet man Klassen von Operationen, und zwar sogenannte *t-Normen* (triangular norms) als Grundlage einer verallgemeinerten Schnittmengenbildung, sogenannte *t-Conormen* als Grundlage einer verallgemeinerten Vereinigung, und sogenannte *Negationen* als Grundlage einer verallgemeinerten Komplementbildung.




Abbildung 1: Die t -Normen $\top_{\min}$, $\top_{\text{prod}}$ und $\top_{\text{Luka}}$.




Abbildung 2: Die t -Conormen $\perp_{\max}$, $\perp_{\text{sum}}$ und $\perp_{\text{Luka}}$.

Definition 2.8. (t -Norm / triangular norm)

Eine Funktion $\top : [0, 1]^2 \rightarrow [0, 1]$ heißt t -Norm, wenn für alle $a, b, c \in [0, 1]$ gilt:

-
- | | | |
|-----|---|---------------------|
| (1) | $\top(a, \top(b, c)) = \top(\top(a, b), c)$ | (Assoziativität) |
| (2) | $\top(a, b) = \top(b, a)$ | (Kommutativität) |
| (3) | $\top(a, 1) = a$ | (neutrales Element) |
| (4) | $a \leq b \Rightarrow \top(a, c) \leq \top(b, c)$ | (Monotonie) |

Die bekanntesten t -Normen sind $\top_{\min}(a, b) = \min\{a, b\}$, $\top_{\text{prod}}(a, b) = a \cdot b$ und $\top_{\text{Luka}}(a, b) = \max\{0, a + b - 1\}$ (nach Jan Łukasiewicz, 1878–1956) [23]. Abb. 1 zeigt ihre Funktionsgraphen. Aus jeder t -Norm erhält man durch elementweise Anwendung eine Schnittmengenbildung. D.h., für zwei Fuzzy-Mengen μ_1 und μ_2 wird der Schnitt definiert als $\forall u \in U: (\mu_1 \cap \mu_2)(u) = \top(\mu_1(u), \mu_2(u))$.

Definition 2.9. (t -Conorm / triangular co-norm)

Eine Funktion $\perp : [0, 1]^2 \rightarrow [0, 1]$ heißt t -Conorm, wenn für alle $a, b, c \in [0, 1]$ gilt:

-
- | | | |
|-----|---|---------------------|
| (1) | $\perp(a, \perp(b, c)) = \perp(\perp(a, b), c)$ | (Assoziativität) |
| (2) | $\perp(a, b) = \perp(b, a)$ | (Kommutativität) |
| (3) | $\perp(a, 0) = a$ | (neutrales Element) |
| (4) | $a \leq b \Rightarrow \perp(a, c) \leq \perp(b, c)$ | (Monotonie) |

Die bekanntesten t -Conormen sind $\perp_{\min}(a, b) = \max\{a, b\}$, $\perp_{\text{prod}}(a, b) = a + b - ab$ und $\perp_{\text{Luka}}(a, b) = \min\{a + b, 1\}$ [23]. Abb. 2 zeigt ihre Funktionsgraphen. Aus jeder t -Conorm erhält man durch elementweise Anwendung eine Vereini-

gungsoperation. D.h., für zwei Fuzzy-Mengen μ_1 und μ_2 wird die Vereinigung definiert als $\forall u \in U: (\mu_1 \cup \mu_2)(u) = \perp(\mu_1(u), \mu_2(u))$.

Definition 2.10. (Negation)

Eine Funktion $n : [0, 1] \rightarrow [0, 1]$ heißt Negation, wenn sie die Bedingungen $n(0) = 1$, $n(1) = 0$ und $\forall a, b \in [0, 1] : a \leq b \Rightarrow n(a) \geq n(b)$ erfüllt.

Am bekanntesten ist die von Zadeh vorgeschlagene Negation $n(a) = 1 - a$ [23]. Aus jeder Negation erhält man durch elementweise Anwendung eine Komplementbildung: Das Komplement $\bar{\mu}$ einer Fuzzy-Menge μ wird definiert als $\forall u \in U: \bar{\mu}(u) = n(\mu(u))$.

Oft werden eine t -Norm und eine t -Conorm über eine Negation zu einem dualen Paar assoziiert. Mit der Negation $\bar{\mu} = 1 - \mu$ werden z.B. die oben genannten t -Normen und t -Conormen mit gleichem Index miteinander assoziiert. Diese Assoziation hat den Vorteil, dass dann die De Morganschen Gesetze gelten, d.h., es gilt $\mu_1 \cup \mu_2 = \bar{\mu}_1 \cap \bar{\mu}_2$ und $\mu_1 \cap \mu_2 = \bar{\mu}_1 \cup \bar{\mu}_2$.

Am häufigsten verwendet man die Negation $n(a) = 1 - a$, die t -Norm $\top_{\min}$ und die zu ihr bezüglich n duale t -Conorm $\perp_{\min}$, da dieser Operationensatz günstige algebraische Eigenschaften hat. So sind Schnitt und Vereinigung idempotent, weil $\mu \cap \mu = \mu$ und $\mu \cup \mu = \mu$ gelten, und es gelten die Distributivgesetze, also

$$\begin{aligned} \mu_1 \cap (\mu_2 \cup \mu_3) &= (\mu_1 \cap \mu_2) \cup (\mu_1 \cap \mu_3) & \text{und} \\ \mu_1 \cup (\mu_2 \cap \mu_3) &= (\mu_1 \cup \mu_2) \cap (\mu_1 \cup \mu_3). \end{aligned}$$

Distributivität ist jedoch in manchen Anwendungen keine wünschenswerte Eigenschaft, so dass mitunter auch andere Operationensätze verwendet werden [23, 22].

3 Methoden und Algorithmen

Kurzgefaßt lässt sich die Idee der Schlussfolgerungsnetze wie folgt beschreiben: Unter bestimmten Bedingungen kann eine Verteilung δ (z.B. eine Wahrscheinlichkeitsverteilung) auf einem mehrdimensionalen Raum, die *A-priori-Wissen* oder *generisches Wissen* über einen bestimmten Anwendungsbereich darstellt, zerlegt werden in eine Menge $\{\delta_1, \dots, \delta_s\}$ von (ggf. überlappenden) Verteilungen auf niedrigdimensionalen Unterräumen. Wenn eine solche Zerlegung möglich ist, dann reicht es aus, die Verteilungen auf den Unterräumen zu kennen, um alle Schlussfolgerungen ziehen zu können, die man mit der ursprünglichen Verteilung δ ziehen kann.

Da eine solche Zerlegung oft durch ein Netz dargestellt wird und da sie zum Ziehen von Schlussfolgerungen dient, nennen wir sie ein *Schlussfolgerungsnetz*. Ein anderer populärer Name ist (*probabilistisches*) *graphisches Modell*, wobei „graphisch“ andeutet, dass es auf einem Graphen (im Sinne der Graphentheorie) beruht. Obwohl diese Beschreibung alle wesentlichen Dinge nennt, ist sie natürlich zu komprimiert, um verständlich zu sein. Im folgenden erklären wir daher zunächst die auftretenden Begriffe und illustrieren anschließend die Idee an einem einfachen Beispiel.

Mit *mehrdimensionalem Raum* meinen wir, dass jeder Zustand eines zu modellierenden Weltausschnitts beschrieben werden kann, indem man die Werte einer Menge von Attributen angibt. Will man z.B. Fahrzeuge beschreiben, so könnte man Hersteller, Modell, Farbe, Motortyp u.ä. angeben. Jedes Attribut — genauer: die Menge der Werte, die es annehmen kann — bildet eine Dimension des Raumes. Dazu müssen die Attributwerte erschöpfend sein und sich gegenseitig ausschließen. Im Fahrzeugbeispiel muß z.B. die Menge der Werte des Attributes „Hersteller“ alle möglichen Hersteller umfassen und kein Fahrzeug darf das gemeinsame Produkt mehrerer Hersteller sein: Für jedes Fahrzeug muss es genau einen Hersteller geben. Mit diesen Einschränkungen (für alle Attribute) entspricht jedes Fahrzeug einem Punkt des durch die Attribute aufgespannten mehrdimensionalen Raumes.

Natürlich kann es mehrere Fahrzeuge geben, die dem gleichen Punkt entsprechen — einfach weil diese Fahrzeuge in allen Attributen übereinstimmen (gleicher Hersteller, gleiche Farbe, gleicher Motortyp etc.). Andererseits kann es Punkte geben, denen kein existierendes Fahrzeug entspricht — z.B. weil ein Motortyp für ein Modell nicht erhältlich ist und es folglich keine entsprechenden Fahrzeuge gibt. Derartige Information ist in der Verteilung auf dem betrachteten Raum enthalten. Eine *Verteilung* δ ordnet jedem Punkt des Raumes eine Zahl aus dem Intervall $[0, 1]$ zu, die die Möglichkeit oder die (A-priori-)Wahrscheinlichkeit angibt, dass der entsprechende Zustand vorliegt. Diese Zahlen werden von Experten geschätzt oder durch statistische Analysen aus Erfahrungsdaten gewonnen. Im Fahrzeugbeispiel könnten diese Zahlen einfach die relative Häufigkeit angeben, mit der Fahrzeuge eines bestimmten Typs und einer bestimmten Ausstattung verkauft wurden.

Mit *Zerlegung* meinen wir, dass die Verteilung δ (wenigstens näherungsweise) aus den Verteilungen $\{\delta_1, \dots, \delta_s\}$ rekonstruiert werden kann, indem man die δ_i geeignet kombiniert. Eine solche Zerlegung hat verschiedene Vorteile, z.B., dass die Verteilungen $\delta_1, \dots, \delta_s$ mit weniger Redundanz gespeichert werden können als die ursprüngliche Verteilung (Zerlegbarkeit zeigt, dass eine Verteilung redundante Information enthält). Wegen dieser Möglichkeit betrachtet man Zerlegungen (von Relationen δ als spezielle Verteilungen) in der Datenbanktheorie [30, 47, 9], die

mit der Theorie der Schlussfolgerungsnetze eng verbunden ist. Der Unterschied ist, dass man sich bei Schlussfolgerungsnetzen auf, wie der Name ja schon sagt, das Ziehen von Schlussfolgerungen konzentriert, während die Datenbanktheorie sich stärker mit dem Speichern, Warten und Abrufen von Daten beschäftigt.

Nur in der Lage zu sein, eine Verteilung effizienter zu speichern, wäre zum Zwecke des Schlussfolgerns allerdings wenig nützlich, gäbe es nicht die Möglichkeit, die Schlussfolgerungen zu ziehen, *ohne die ursprüngliche Verteilung vorher rekonstruieren zu müssen*. Die Kernidee ist, (Beobachtungs-)Informationen lokal von Unterraum zu Unterraum weiterzugeben, bis alle Verteilungen aktualisiert sind. Diesen Vorgang nennt man *Evidenzpropagation*. Wie er abläuft, lässt sich am besten an einem einfachen Beispiel zeigen. In diesem Beispiel vernachlässigen wir zunächst die Wahrscheinlichkeiten, die leicht die sehr einfache Idee verschleiern können, und betrachten nur, ob bestimmte Zustände eines gegebenen Weltausschnitts möglich sind oder nicht. D.h., wir betrachten zunächst Netze, die man *relationale Netze* nennen könnte, und erst anschließend echte probabilistische Netze (die Möglichkeit eines Ereignisses durch seine Wahrscheinlichkeit ersetzend).

3.1 Beispiele

Wir betrachten einige geometrische Objekte, die drei Eigenschaften haben: Farbe, Form und Größe (Abb. 3). Diese Objekte kann man auch als Relation oder Tabelle darstellen, in der jede Zeile ein Objekt beschreibt.




Abbildung 3: Einige geometrische Objekte und ihre Darstellung als Tabelle bzw. Relation.

Farbe	Form	Größe
■	○	klein
■	○	mittel
▨	○	klein
▨	○	mittel
▩	△	mittel
▩	△	groß
□	□	mittel
■	□	mittel
■	△	mittel
■	△	groß

Es werde nun zufällig ein Objekt aus dieser Menge ausgewählt. Wir nehmen jedoch an, dass nicht alle Eigenschaften des Objektes beobachtet werden können. Man kann sich dazu vorstellen, dass jemand in einiger Entfernung ein Objekt aus einer Kiste zieht, so dass nur die Farbe erkennbar ist, nicht aber die Form oder die Größe. Wir wissen aber, dass es nur zehn verschiedene Objekte mit bestimmten Kombinationen der drei Eigenschaften gibt. Wie kann man dies ausnutzen, um etwas über die nicht beobachteten Eigenschaften des Objektes zu erschließen?

Probleme dieser Art treten in vielen Anwendungen auf, z.B. der medizinischen Diagnose: Ein Arzt verfügt über Lehrbuch- und Erfahrungswissen über

Abhängigkeiten zwischen Symptomen, physiologischen Zuständen und Krankheiten, ggf. im Kontext anderer Patienteneigenschaften, z.B. Alter und Geschlecht. Beobachten bzw. erfragen kann er aber nur Symptome sowie Alter, Geschlecht etc. Welche Krankheit (wahrscheinlich) vorliegt, muss er mit Hilfe seines Wissens erschließen.

Bei den geometrischen Objekten ist die Schlussfolgerung trivial: Z.B. sortiert man in der Tabelle alle Objekte mit einer anderen Farbe als der beobachteten aus und stellt für die restlichen die möglichen Formen und Größen zusammen. Dies ist aber nur möglich, weil wir nur zehn Objekte mit nur drei Eigenschaften haben. In der medizinischen Diagnose können wir kaum so vorgehen, da die Tabelle, die wir aufstellen müßten, viel zu groß ist, um auf diese Weise bearbeitet werden zu können. Stattdessen müssen wir das medizinische Wissen des Arztes geeignet strukturieren, z.B. durch Zerlegung in Abhängigkeiten zwischen wenigen Eigenschaften.

Wie (tabellarisches) Wissen zerlegt werden kann, so dass es handhabbar wird, lässt sich bereits am Beispiel der Menge geometrischer Objekte zeigen: Die Eigenschaftstabelle dieser Objekte lässt sich ohne Verlust auf zwei kleinere Tabellen aufteilen. Dazu stellen wir

den Schlussfolgerungsraum graphisch dar, wie in Abb. 4 links gezeigt: wir ordnen jeder Eigenschaft eine Raumrichtung zu, so dass sich jede mögliche Kombination von Eigenschaftswerten durch einen Würfel in diesem Raum darstellen lässt. Tragen wir die zu den Objekten unseres Beispiels gehörenden Würfel in diesen Schlussfolgerungsraum ein, so ergibt sich das in Abb. 4 rechts gezeigte Bild.




Abbildung 4: Schlussfolgerungsraum und graphische Darstellung der Relation.

Nehmen wir an, das ausgewählte Objekt sei hellgrau. In der Darstellung von Abb. 4 entspricht das Schlussfolgern durch Einschränkung auf hellgraue Objekte dem Herausschneiden der zur Farbe Hellgrau gehörenden „Scheibe“ des Schlussfolgerungsraums, wie es in Abb. 5 gezeigt ist. Wir erhalten, dass das

Objekt kein Kreis sein kann, sondern ein Quadrat oder Dreieck sein muss, und dass es nicht klein sein kann, sondern mittelgroß oder groß sein muss.




Abbildung 5: Direktes Schlussfolgern

Diese Schlussfolgerung lässt sich jedoch auch anders ziehen, da das Wissen über die Eigenschaftskombinationen der Objekte zerlegt werden kann, und zwar in sogenannte *Projektionen* auf zweidimensionale Unterräume. Alle möglichen

derartigen Projektionen sind in Abb. 6 gezeigt. Sie ergeben sich als Schattenwürfe, wenn man sich Lichtquellen vor, über und rechts dieser Blockanordnung vorstellt.




Abbildung 6: Alle drei zweidimensionalen Projektionen der Relation




Abbildung 7: Zwei zylindrische Erweiterungen von Projektionen und ihr Schnitt

Wir können die Relation in die Projektionen auf die hintere und die linke Seitenfläche des Schlussfolgerungsraums zerlegen, denn aus diesen lässt sie sich rekonstruieren. Dies ist in Abb. 7 gezeigt. Wir gehen folgendermaßen vor: Zunächst werden die sogenannten *zylindrischen Erweiterungen* der beiden Projektionen gebildet. D.h., wir fügen in der jeweils fehlenden Dimension alle möglichen Werte hinzu. Dies ist in Abb. 7 oben und rechts gezeigt.³ Die so erhaltenen Würfelanordnungen werden anschließend miteinander geschnitten, d.h., es bleiben nur die Würfel übrig, die in beiden zylindrischen Erweiterungen enthalten sind. Das Ergebnis ist in Abb. 7 gezeigt. Wie man leicht sieht, stimmt es mit der graphischen Darstellung der Relation aus Abb. 4 überein.

Der Vorteil der Zerlegung, dass sie sich zum Schlussfolgern nutzen lässt, ohne dass die dreidimensionale Darstellung wiederhergestellt werden muss. Abb. 8 zeigt das Vorgehen. Zuerst wird die Beobachtung, dass das Objekt hellgrau ist, auf den Unterraum $\text{Farbe} \times \text{Form}$




Abbildung 8: Evidenzpropagation

³ Der Name „zylindrische Erweiterung“ für diese Operation leitet sich von der üblichen Praxis ab, in Skizzen Mengen durch Kreisscheiben darzustellen: Fügt man zu einer Kreisscheibe eine Dimension hinzu, so erhält man einen Zylinder.

zylindrisch erweitert (schraffierte Spalte) und mit der Projektion der Relation auf diesen Raum (grau unterlegte Felder) geschnitten. Das Ergebnis wird auf die Dimension Form projiziert. Man erhält, dass das Objekt kein Kreis sein kann, sondern ein Quadrat oder ein Dreieck sein muss. Dieses Zwischenergebnis wird in analoger Weise auf den Unterraum Form×Größe zylindrisch erweitert (schraffierte Zeilen), mit der Projektion der Relation auf diesen Raum (graue Felder) geschnitten und schließlich auf die Dimension Größe projiziert. Man erhält, dass das Objekt nicht klein sein kann, sondern mittelgroß oder groß sein muss.

Dieses Verfahren, Schlussfolgerungen zu ziehen, rechtfertigt die Darstellung durch ein Netz, wie es in Abb. 9 gezeigt ist. Jeder Eigenschaft entspricht ein Knoten und die Kanten geben an, welche Projektionen benötigt werden. Es wird natürlich nicht immer auf zweidimensionale Unterräume projiziert. Dass wir nur solche Projektionen betrachten, liegt an der Einfachheit des Beispiels. In Anwendungen können die Unterräume, auf die projiziert wird, drei, vier oder noch mehr Dimensionen haben. Entsprechend verbinden die Kanten dann mehr als zwei Knoten (man spricht in diesem Fall von *Hyperkanten*). Eine Darstellung der Attributmengen, die so verbunden werden, durch z.B. einen Verbundbaum kann hier hilfreich sein (siehe unten).

Man beachte, dass die Projektionen sorgfältig gewählt werden müssen. Die Relation aus Abb. 3 lässt sich nicht in zwei beliebige Projektionen zerlegen. Dies zeigt Abb. 10. Statt der Projektion auf die hintere Fläche wird hier die Projektion auf die untere verwendet. Der Schnitt der zylindrischen Erweiterungen (unten links) ist jedoch deutlich verschieden von der Originalrelation (oben rechts): Er enthält 6 zusätzliche Objekte.

Man kann nicht einmal immer eine Zerlegung finden: In Abb. 11 sind zwei Würfel markiert. Wenn wir annehmen, dass das zu dem mit einer 1 markierten Würfel gehörende Objekt entfernt wird dann kann die Relation nicht mehr in zwei Projektionen



Abbildung 9: Netzwerkdarstellung




Abbildung 10: Andere Projektionen




Abbildung 11: Ist eine Zerlegung immer möglich?




Abbildung 12: Eine dreidimensionale Wahrscheinlichkeitsverteilung und direktes Schlussfolgern in dieser Verteilung (d.h. Berechnung einer bedingten Verteilung).

auf zweidimensionale Unterräume zerlegt werden, wie man leicht ausprobieren kann. Man kann sich zwar noch behelfen, indem man alle drei Projektionen verwendet, denn da das Entfernen des Würfels 1 die Projektion auf die untere Fläche ändert, ist der Würfel 1 in der zylindrischen Erweiterung dieser Projektion und damit im Schnitt aller drei Projektionen nicht mehr enthalten. Wird dagegen das Objekt entfernt, das zu dem mit einer 2 markierten Würfel gehört, lässt sich die Relation gar nicht mehr zerlegen. Denn das Entfernen dieses Würfels ändert keine der drei Projektionen: In jeder Raumrichtung gibt es noch einen anderen Würfel, der den Schatten wirft. Der Würfel ist daher im Schnitt der Projektionen enthalten.

Allerdings wird man, da in der Praxis das Schlussfolgern im Gesamttraum wegen der großen Zahl zu betrachtender Eigenschaften i.A. unmöglich wird, versuchen, nicht (exakt) zerlegbares Wissen wenigstens näherungsweise zu zerlegen. Ziel ist es, eine Zerlegung zu finden, die möglichst wenige zusätzliche Eigenschaftskombinationen für möglich erklärt (es können nur Eigenschaftskombinationen hinzukommen).

Man beachte, dass dieses Beispiel aus didaktischen Gründen sehr klein gehalten wurde. In Anwendungen wie z.B. der Beschreibung von Bauvarianten von Fahrzeugen hat man es dagegen typischerweise mit einigen hundert Variablen mit zwei (Sitzheizung ja/nein) bis 50 (Art des Sitzbezugs) Werten zu tun [12]. Trotzdem ist das Zerlegungsprinzip weiterhin anwendbar. Nur werden sehr viel mehr und größere Unterräume benötigt. Mit heutigen Rechnern ist das jedoch leicht zu bewältigen.

Die Idee der Zerlegung einer Relation lässt sich leicht auf Wahrscheinlichkeitsverteilungen übertragen. Wir erweitern dazu das Beispiel, wie in Abb. 12 gezeigt, indem wir jeder Kombination der drei Eigenschaften der geometrischen

Objekte eine Wahrscheinlichkeit zuordnen. Das Beispiel ist so gewählt, dass Eigenschaftskombinationen, die vorher möglich waren, nun eine hohe, solche, die unmöglich waren, eine niedrige Wahrscheinlichkeit haben.

Zu dieser Verteilung sind außerdem die *Randverteilungen* angegeben. Sie werden durch Summieren über die herausfallende Dimension bzw. Dimensionen berechnet.⁴ So ergibt sich etwa der Wert von 40 Promille für schwarze Dreiecke in der unten links in Abb. 12 gezeigten Randverteilung auf dem Unterraum Farbe $\times$ Form als Summe der Wahrscheinlichkeiten von 2, 18 und 20 Promille für kleine, mittlere und große schwarze Dreiecke, der Wert von 460 Promille für mittelgroße Objekte als Summe der Wahrscheinlichkeiten der mittleren Tafel.

Zum Schlussfolgern schränken wir die Verteilung auf die „Scheibe“ ein, die dem Wert des beobachteten Attributes entspricht: Das Objekt ist hellgrau. Diese Wahrscheinlichkeit wird auf 1 gesetzt (denn diese Farbe ist jetzt sicher), die Wahrscheinlichkeit aller anderen Farben auf 0 (denn sie sind jetzt unmöglich). Die Werte in den Tafeln des Schemas werden angepasst, indem die zu den Farben gehörenden „Scheiben“ mit dem Quotienten der Wahrscheinlichkeiten vor und nach der Beobachtung multipliziert. Dadurch werden die bedingten Wahrscheinlichkeiten der verschiedenen Wertkombinationen berechnet gegeben die Beobachtung, dass das Objekt hellgrau ist.⁵ Durch Summation über die Zeilen bzw. Spalten der „Scheibe“ erhalten wir die bedingten (Rand-)Wahrscheinlichkeiten der Formen und Größen.

Wie die Relation aus Abb. 4, so lässt sich auch die betrachtete Wahrscheinlichkeitsverteilung in die Projektionen (Randverteilungen) auf die Unterräume Farbe $\times$ Form und Form $\times$ Größe zerlegen, denn aus diesen lässt sie sich folgendermaßen rekonstruieren: Um z.B. die Wahrscheinlichkeit kleiner schwarzer Dreiecke zu bestimmen, multipliziert man die Wahrscheinlichkeit schwarzer Dreiecke (40 Promille) mit der Wahrscheinlichkeit kleiner Dreiecke (20 Promille) und teilt durch die (doppelt berücksichtigte) Wahrscheinlichkeit von Dreiecken (400 Promille). Man erhält 2 Promille, wie auch in der dreidimensionalen Verteilung ausgewiesen.

Diese Zerlegbarkeit lässt sich zum Schlussfolgern nutzen. Das Prinzip ist in Abb. 13 gezeigt. Die neue Wahrscheinlichkeit hellgrauer Objekte ist 1. Die Randverteilung auf dem Unterraum Farbe $\times$ Form wird spaltenweise mit dem Quotienten der neuen und der alten Wahrscheinlichkeiten multipliziert. Man erhält aus den alten Wahrscheinlichkeiten im oberen Teil eines Feldes die im unteren Teil angegebenen neuen. Das Ergebnis wird durch zeilenweise Summa-

⁴ Siehe dazu den Satz 2.4 über die vollständige Wahrscheinlichkeit auf Seite 9.

⁵ Siehe die Definition der bedingten Wahrscheinlichkeit in Definition 2.3 auf Seite 8.




Abbildung 13: Propagation der Evidenz, dass das Objekt hellgrau ist (alle Angaben in Promille).

tion auf die Dimension Form projiziert, was die neuen Wahrscheinlichkeiten der Objektformen liefert. Im zweiten Schritt wird die Randverteilung auf dem Unterraum Form $\times$ Größe zeilenweise mit dem Quotienten aus alter und neuer Formwahrscheinlichkeit multipliziert und anschließend durch spaltenweise Summation auf die Dimension Größe projiziert, was die neuen Wahrscheinlichkeiten der Objektgrößen liefert.

Dies rechtfertigt wieder eine Netzdarstellung wie in Abb. 9. Die spezielle Art probabilistischer Netze, die mit Randverteilungen arbeitet, nennt man Markow-Netze (nach Andrej A. Markow, 1856–1922). Eine Alternative sind Bayes-Netze (nach Thomas Bayes, 1702–1761), die mit bedingten Verteilungen arbeiten und in denen die Kanten des Netzwerks gerichtet sind (siehe unten).

Auch bei der Zerlegung von Wahrscheinlichkeitsverteilungen müssen die Projektionen sorgfältig gewählt werden, da nicht jede Wahl einer Menge von Randverteilungen eine Zerlegung darstellt, und auch Wahrscheinlichkeitsverteilungen sind nicht immer zerlegbar. Bei nicht zerlegbaren Verteilungen wird man wieder versuchen, eine gute Näherung zu finden, bei der die aus den Randverteilungen berechneten Wahrscheinlichkeiten möglichst wenig von den tatsächlichen abweichen.

3.2 Bedingte Unabhängigkeit

Warum ist die Wahrscheinlichkeitsverteilung auf dem Raum geometrischer Objekte zerlegbar? Sei Attribut A die Farbe, Attribut B die Form und Attribut C die Größe eines Objektes und $\text{dom}(A)$, $\text{dom}(B)$ bzw. $\text{dom}(C)$ die zugehörigen Werte-

bereiche⁶. Dann gilt in Abb. 12 $\forall a \in \text{dom}(A) : \forall b \in \text{dom}(B) : \forall c \in \text{dom}(C) :$

$$\begin{aligned} P(A = a \wedge B = b \wedge C = c) &= \frac{P(A = a \wedge B = b) \cdot P(B = b \wedge C = c)}{P(B = b)} \\ &= P(A = a \wedge B = b) \cdot P(C = c \mid B = b) \\ &= P(B = b \wedge C = c) \cdot P(A = a \mid B = b). \end{aligned}$$

Diese Gleichung gilt sicherlich nicht allgemein. Im allgemeinen Fall gilt lediglich (Produktsatz der Wahrscheinlichkeitsrechnung, Satz 2.3 auf Seite 8) $\forall a, b, c :$

$$\begin{aligned} P(A = a \wedge B = b \wedge C = c) &= P(A = a \wedge B = b) \cdot P(C = c \mid A = a \wedge B = b) \\ &= P(B = b \wedge C = c) \cdot P(A = a \mid B = b \wedge C = c). \end{aligned}$$

Durch Vergleich der beiden obigen Gleichungen finden wir, dass

$$\begin{aligned} P(A = a \mid C = c \wedge B = b) &= P(A = a \mid B = b) \quad \text{und} \\ P(C = c \mid A = a \wedge B = b) &= P(C = c \mid B = b) \quad \text{gilt.} \end{aligned}$$

D.h., für alle Werte a, b und c müssen die Ereignisse $A = a$ und $C = c$ *bedingt unabhängig* sein gegeben das Ereignis $B = b$. (Siehe Definition 2.4 der stochastischen Unabhängigkeit von Ereignissen sowie Satz 2.2 auf Seite 8.) Um die Quantifizierung mit allen möglichen Attributwerten zu sparen, sagt man abkürzend, dass die Attribute A und C *bedingt unabhängig* seien gegeben das Attribut B .

Offenbar spielt bedingte Unabhängigkeit eine wichtige Rolle. In der Tat beruht die Möglichkeit, Zerlegungen durch Graphen darzustellen, darauf, dass die Begriffe der bedingten Unabhängigkeit von Attributen und der *Trennung* von Knoten in einem Graphen eng verwandt sind. Sogenannte *bedingte Unabhängigkeitsgraphen*, die über den Begriff der Trennung von Knoten eine Menge von bedingten Unabhängigkeitsaussagen darstellen, beschreiben eine Zerlegung einer Verteilung. Man betrachte dazu den Graphen aus Abb. 9, in dem der einzige Pfad vom Attribut A (Farbe) zum Attribut C (Größe) durch das Attribut B (Form) blockiert ist. Dies drückt die bedingte Unabhängigkeit von A und C gegeben B aus.

Für die Untersuchung bedingter Unabhängigkeiten ist eine axiomatische Fassung günstig. Diese Axiomatisierung des Unabhängigkeitsbegriffs hat den Vorteil, dass man nicht an Wahrscheinlichkeitstheorie gebunden ist, sondern auch andere Kalküle, z.B. Possibilitätstheorie, betrachten kann.

⁶ In der Wahrscheinlichkeitstheorie werden die Attribute A, B, C als Zufallsvariablen bezeichnet. Die Notation $P(\text{Form} = \text{Dreieck})$ steht dabei für die Wahrscheinlichkeit, dass die Zufallsvariable *Form* den Wert *Dreieck* annimmt.

Axiome zur Beschreibung bedingter Unabhängigkeit wurden schon von [10], aber später auch unabhängig von [31] angegeben. Die folgende Definition führt außerdem eine Schreibweise für bedingte Unabhängigkeiten ein.

Definition 3.1. *Sei U eine Menge mathematischer Objekte, $(\cdot \perp\!\!\!\perp \cdot \mid \cdot)$ eine 3-stellige Relation auf der Potenzmenge 2^U von U und W, X, Y und Z vier disjunkte Teilmengen von U . Dann heißen die Aussagen*

<i>Symmetrie:</i>	$(X \perp\!\!\!\perp Y \mid Z) \Rightarrow (Y \perp\!\!\!\perp X \mid Z)$
<i>Zerlegung:</i>	$(W \cup X \perp\!\!\!\perp Y \mid Z) \Rightarrow (W \perp\!\!\!\perp Y \mid Z) \wedge (X \perp\!\!\!\perp Y \mid Z)$
<i>Schwache Vereinigung:</i>	$(W \cup X \perp\!\!\!\perp Y \mid Z) \Rightarrow (X \perp\!\!\!\perp Y \mid Z \cup W)$
<i>Zusammenziehung:</i>	$(X \perp\!\!\!\perp Y \mid Z \cup W) \wedge (W \perp\!\!\!\perp Y \mid Z) \Rightarrow (W \cup X \perp\!\!\!\perp Y \mid Z)$

Semi-Graphoid-Axiome. *Eine 3-stellige Relation $(\cdot \perp\!\!\!\perp \cdot \mid \cdot)$, die die Semi-Graphoid-Axiome für alle W, X, Y, Z erfüllt, heißt Semi-Graphoid.*

Definition 3.2. *Fügt man zu der Menge der Semi-Graphoid-Axiomen zusätzlich das folgende Axiom hinzu:*

Schnitt:	$(W \perp\!\!\!\perp Y \mid Z \cup X) \wedge (X \perp\!\!\!\perp Y \mid Z \cup W) \Rightarrow (W \cup X \perp\!\!\!\perp Y \mid Z)$
-----------------	---

so erhält man die Graphoid-Axiome. Eine Relation $(\cdot \perp\!\!\!\perp \cdot \mid \cdot)$, die diese Axiome für alle W, X, Y, Z erfüllt, heißt ein Graphoid.

Mit der Menge U ist natürlich die Menge der Attribute gemeint, die zur Beschreibung des zu modellierenden Weltausschnitts verwendet werden. Die dreistellige Relation $(\cdot \perp\!\!\!\perp \cdot \mid \cdot)$ stellt einen Begriff bedingter Unabhängigkeit von Attributen bzw. Attributmengen dar, und zwar bedeutet $X \perp\!\!\!\perp Y \mid Z$, dass X bedingt unabhängig ist von Y gegeben Z . Diese Axiome lassen sich durch Überlegungen zur Wirkung des Bekanntwerdens von Information über einige Mengen von Attributen auf andere Mengen von Attributen intuitiv interpretieren [32].

Satz 3.1. *Bedingte stochastische Unabhängigkeit erfüllt die Semi-Graphoid-Axiome, für strikt positive Wahrscheinlichkeitsverteilungen die Graphoid-Axiome.*

Der Beweis ist leicht zu führen und findet sich z.B. in [6]. Dieser Satz stellt die Korrektheit der (Semi-)Graphoid-Axiome für Schlussfolgerungen über bedingte (stochastische) Unabhängigkeit sicher. Die von [32] aufgestellte Vermutung, die Semi-Graphoid-Axiome seien für allgemeine (nicht nur strikt positive) Wahrscheinlichkeitsverteilungen auch vollständig, hat sich jedoch als falsch erwiesen [46].

3.3 Darstellung durch Graphen

Ein Begriff bedingter Unabhängigkeit, der die oben genannten Axiome erfüllt, ist sehr ähnlich zur Trennung von Knoten bzw. Knotenmengen in Graphen. Dies ermöglicht die Darstellung von (Mengen von) bedingten Unabhängigkeitsaussagen durch (Knotentrennung in) Graphen.

Ein *Graph* ist ein Tupel $G = (V, E)$, bestehend aus einer (endlichen) Menge $V = \{A_1, \dots, A_n\}$ von n *Knoten* (*vertices*) und einer Menge $E \subseteq (V \times V) \setminus \{(A, A) \mid A \in V\}$ von *Kanten* (*edges*). Mit dieser Definition sind die Graphen, die wir betrachten, *einfach* (zwischen zwei Knoten gibt es höchstens eine Kante) und *schleifenfrei* (es gibt keine Kante von einem Knoten zu sich selbst). Wir nennen eine Kante $(A, B) \in E$ *gerichtet* (von A nach B), wenn $(B, A) \notin E$, und *ungerichtet*, wenn auch $(B, A) \in E$ (bei ungerichteten Kanten sind beide Richtungen vorhanden).

Sind zwei Knoten A und B durch eine gerichtete Kante (A, B) verbunden, so sagen wir, daß A der *Elternknoten* (oder kurz der *Elter*) von B und B der *Kindknoten* (oder kurz das *Kind*) von A ist. Die *Familie* eines Knotens A besteht aus dem Knoten A selbst und seinen Elternknoten. Ein Knoten A heißt *benachbart* oder *adjacent* zu einem Knoten B , wenn $(A, B) \in E$ oder $(B, A) \in E$. Der Knoten B heißt dann auch *Nachbar* von A (und umgekehrt). In einem gerichteten Graphen sind die Nachbarn eines Knotens gerade seine Kinder und seine Eltern. Wir unterscheiden *gerichtete* und *ungerichtete* Graphen danach, ob sie ausschließlich gerichtete oder ausschließlich ungerichtete Kanten enthalten. Wenn nötig, werden wir bei gerichteten Graphen zur Unterscheidung $\vec{G}$ für den Graphen und $\vec{E}$ für die Kantenmenge schreiben. Gemischte Graphen (die sowohl gerichtete als auch ungerichtete Kanten enthalten) werden wir nicht betrachten.

Zwei Knoten A und B heißen *verbunden* in $G = (V, E)$, geschrieben $A \sim B$, wenn es eine Folge $\langle C_1, \dots, C_k \rangle$ paarweise verschiedener Knoten, *Pfad* genannt, gibt mit $C_1 = A$, $C_k = B$ und $\forall i, 1 \leq i < k : (C_i, C_{i+1}) \in E \vee (C_{i+1}, C_i) \in E$. Ein Graph $G = (V, E)$ ist ein *Baum*, wenn für jedes Knotenpaar $A, B \in V$ nur genau ein Pfad existiert, der sie verbindet. In einem Baum heißen Knoten mit nur einem Nachbarn *Blätter*, alle anderen *innere Knoten*. Ein Pfad heißt *gerichtet*, wenn $\forall i, 1 \leq i < k : (C_i, C_{i+1}) \in E$, d.h. ein gerichteter Pfad folgt stets der Richtung der Kanten. Wir schreiben dann $A \rightsquigarrow B$ und sagen, daß A ein *Vorfahre* von B und B ein *Nachfahre* von A ist. Ein gerichteter Graph heißt *kreisfrei* oder *azyklisch*, wenn $\forall A, B \in E : A \rightsquigarrow B \Rightarrow (B, A) \notin E$, d.h. man kann nicht zu einem Knoten zurückkehren, wenn man der Richtung der Kanten folgt.

Was unter „Trennung“ von Knoten und Knotenmengen in Graphen zu verstehen ist, hängt von der Art des Graphen ab. Für ungerichtete Graphen definiert man:

Definition 3.3. Sei $G = (V, E)$ ein ungerichteter Graph und X, Y und Z drei disjunkte Knotenmengen. Z u -trennt X und Y in G , geschrieben $\langle X \mid Z \mid Y \rangle_G$, genau dann, wenn alle Pfade von einem Knoten aus X zu einem Knoten aus Y einen Knoten aus Z enthalten. Enthält ein Pfad einen Knoten aus Z , so heißt dieser Pfad (durch Z) blockiert, sonst aktiv.


Für gerichtete Graphen wird ein komplizierteres Kriterium verwendet [32, 13, 48], das weniger natürlich ist als die u -Trennung, aber die bedingten Unabhängigkeiten erfasst, die man bei einer Zerlegung mit dem Produktsatz ausnutzt (siehe unten).

Definition 3.4. Sei $\vec{G} = (V, \vec{E})$ ein gerichteter azyklischer Graph und seien X, Y und Z drei disjunkte Teilmengen von Knoten. Z d -trennt X und Y in $\vec{G}$, geschrieben $\langle X \mid Z \mid Y \rangle_{\vec{G}}$, genau dann, wenn es keinen Pfad von einem Knoten aus X zu einem Knoten aus Y gibt, auf dem die folgenden Bedingungen gelten:

1. Jeder Knoten, an dem Kanten zusammenlaufen (d.h., an dem die beiden diesen Knoten berührenden Kanten des Pfades auf diesen Knoten gerichtet sind), ist selbst aus Z oder hat einen (direkten oder indirekten) Nachfolger in Z .
2. Jeder andere Knoten ist nicht in Z .

Wenn entlang eines Pfades die beiden obigen Bedingungen gelten, so heißt dieser Pfad aktiv, anderenfalls heißt er (durch Z) blockiert.

Beispiel 3.1. In dem rechts gezeigten Graphen gilt $\langle A \mid \emptyset \mid B \rangle$, da der Pfad $A \rightarrow C \leftarrow B$ blockiert ist, wenn keine Attribute gegeben sind, aber es gilt nicht $\langle A \mid F \mid B \rangle$, da der Pfad $A \rightarrow C \leftarrow B$ durch den Nachfolger F von C aktiviert wird. Es gilt $\langle A \mid C \mid E \rangle$, da der Pfad $A \rightarrow C \rightarrow E$ durch C blockiert ist, aber nicht $\langle B \mid C \mid F \rangle$, da zwar der Pfad $B \rightarrow C \rightarrow F$ blockiert ist, nicht jedoch der Pfad $B \rightarrow D \rightarrow F$. Es gilt $\langle C \mid B \mid D \rangle$, da der Pfad $C \leftarrow B \rightarrow D$ durch B und der Pfad $C \rightarrow F \leftarrow D$ dadurch blockiert ist, dass weder F noch ein Nachfolger von F (den es hier auch gar nicht gibt) gegeben sind.



Sowohl u - als auch d -Trennung erfüllen die Graphoid-Axiome. Für die u -Trennung ist dies aus der in Abb. 14 gezeigten Illustration der Graphoid-Axiome [32] (mit Ausnahme der offensichtlichen Symmetrie) ersichtlich. Auch für den Nachweis, dass die d -Trennung die Graphoid-Axiome erfüllt, ist diese Illustration hilfreich.

Die Tatsache, dass die Trennung von Knoten in Graphen die gleichen Axiome erfüllt, die auch ein Begriff bedingter Unabhängigkeit erfüllen sollte, legt




Abbildung 14: Illustration der Graphoid-Axiome und der Trennung in Graphen.

es nahe, eine Menge bedingter Unabhängigkeitsaussagen durch einen Graphen darzustellen. Das können z.B. alle bedingten Unabhängigkeitsaussagen sein, die in einer gegebenen Wahrscheinlichkeitsverteilung gelten. Im Idealfall können wir dann an dem Graphen ablesen, ob zwei Attributmengen bedingt unabhängig sind gegeben eine dritte, indem wir feststellen, ob sie durch die dritte Attributmenge in diesem Graphen getrennt werden. Leider lässt sich dieses Optimum, also die völlige Isomorphie der bedingten Unabhängigkeit von Attributen und ihrer Trennung in einem Graphen, nicht im allgemeinen Fall erreichen. Dies liegt erstens daran, dass speziell die u -Trennung Axiome erfüllt, die deutlich stärker sind als die Graphoid-Axiome [31], so dass aus Aussagen über die Trennung von Knoten andere folgen, deren Analoga aus den entsprechenden bedingten Unabhängigkeitsaussagen nicht gefolgert werden können. Zweitens erfüllt die bedingte stochastische Unabhängigkeit im allgemeinen Fall nur die Semi-Graphoid-Axiome, so dass bereits Ableitungen mit dem Schnittaxiom ungültig sein können. Drittens gibt es Fälle, in denen bestimmte bedingte Unabhängigkeitsaussagen, die gleichzeitig in einer Verteilung gelten können, aber keine logischen Folgerungen von einander sind, nicht gleichzeitig durch einen Graphen dargestellt werden können [2].

Folglich müssen wir eine schwächere Definition benutzen, als die Isomorphie von bedingter Unabhängigkeit und Trennung zu fordern [32]. Diese Definition ist jedoch ausreichend, da zur Beschreibung von Zerlegungen, die ja unser eigentliches Ziel ist, diese Isomorphie zwar wünschenswert, aber nicht unerlässlich ist.

Definition 3.5. Sei $(\cdot \perp_{\delta} \cdot \mid \cdot)$ eine 3-stellige Relation, die die bedingten Unabhängigkeiten darstellt, die in einer Verteilung δ über einer Attributmenge U gelten. Ein ungerichteter Graph $G = (U, E)$ heißt bedingter Abhängigkeitsgraph (conditional dependence graph) oder Abhängigkeitskarte (dependence

map) für δ genau dann, wenn für alle disjunkten Teilmengen $X, Y, Z \subseteq U$ gilt $X \perp\!\!\!\perp_\delta Y \mid Z \Rightarrow \langle X \mid Z \mid Y \rangle_G$, d.h., wenn G durch u -Trennung alle in δ geltenden (bedingten) Unabhängigkeiten erfasst. Analog heißt G bedingter Unabhängigkeitsgraph (conditional independence graph) oder Unabhängigkeitskarte (independence map) für δ genau dann, wenn für alle disjunkten Teilmengen $X, Y, Z \subseteq U$ gilt $\langle X \mid Z \mid Y \rangle_G \Rightarrow X \perp\!\!\!\perp_\delta Y \mid Z$, d.h., wenn G durch u -Trennung nur in δ geltende (bedingte) Unabhängigkeiten darstellt. Ist G sowohl Abhängigkeits- als auch Unabhängigkeitskarte für eine gegebene Verteilung δ , so heißt G perfekte Karte (perfect map) für δ .


Ein leerer Graph ist eine triviale Abhängigkeitskarte, ein vollständiger Graph eine triviale Unabhängigkeitskarte, und nicht jede Verteilung besitzt eine perfekte Karte. Für gerichtete azyklische Graphen werden die Begriffe analog definiert.

Wir beschränken uns auf bedingte Unabhängigkeitsgraphen, da es die bedingten Unabhängigkeiten sind, die es ermöglichen, eine Verteilung zu zerlegen. Es sollten daher keine ungültigen bedingten Unabhängigkeiten ablesbar sein, denn sonst ergibt sich möglicherweise keine korrekte Zerlegung der Verteilung.

Definition 3.6. Eine Wahrscheinlichkeitsverteilung p_U über einer Attributmenge $U = \{A_1, \dots, A_n\}$ heißt zerlegbar oder faktorisierbar bezüglich eines ungerichteten Graphen G genau dann, wenn sie als Produkt von nichtnegativen Funktionen auf den maximalen Cliques von G geschrieben werden kann. Genauer: Sei $\mathcal{M}$ eine Familie von Teilmengen von U , so dass die durch die Mengen $M \in \mathcal{M}$ induzierten Teilgraphen die maximalen Cliques von G sind. Sei außerdem $\mathcal{E}_M$ die Menge der Ereignisse, die sich durch Zuweisung von Werten an alle Attribute in M beschreiben lassen. Dann heißt p_U zerlegbar oder faktorisierbar bzgl. G , wenn es Funktionen $\phi_M : \mathcal{E}_M \rightarrow \mathbb{R}_0^+$, $M \in \mathcal{M}$, gibt, so dass $\forall a_1 \in \text{dom}(A_1) : \dots \forall a_n \in \text{dom}(A_n) :$

$$p_U \left(\bigwedge_{A_i \in U} A_i = a_i \right) = \prod_{M \in \mathcal{M}} \phi_M \left(\bigwedge_{A_i \in M} A_i = a_i \right).$$

Beispiel 3.2. Der rechts gezeigte ungerichtete Graph besitzt vier maximale Cliques, nämlich die Teilgraphen, die von den Mengen $\{A_1, A_2, A_3\}$, $\{A_3, A_5, A_6\}$, $\{A_2, A_4\}$, und $\{A_4, A_6\}$ gebildet werden. Er stellt eine Faktorisierung einer Wahrscheinlichkeitsverteilung über dem gemeinsamen Wertebereich der Attribute A_1 bis A_6 gemäß der folgenden Formel dar: $\forall a_1 \in \text{dom}(A_1) : \dots \forall a_6 \in \text{dom}(A_6) :$



$$\begin{aligned}
p_U(A_1 = a_1 \wedge \dots \wedge A_6 = a_6) &= \phi_{A_1 A_2 A_3}(A_1 = a_1, A_2 = a_2, A_3 = a_3) \\
&\cdot \phi_{A_3 A_5 A_6}(A_3 = a_3, A_5 = a_5, A_6 = a_6) \\
&\cdot \phi_{A_2 A_4}(A_2 = a_2, A_4 = a_4) \\
&\cdot \phi_{A_4 A_6}(A_4 = a_4, A_6 = a_6).
\end{aligned}$$

Für solche Zerlegungen gilt der folgende Satz, der üblicherweise [16] zugeschrieben wird, die ihn für den diskreten Fall bewiesen haben (auf den wir uns hier auch beschränken), obwohl, laut [27], dieses Ergebnis von verschiedenen Autoren in unterschiedlichen Formen entdeckt worden zu sein scheint.

Theorem 3.1. *Eine strikt positive Wahrscheinlichkeitsverteilung p_U über einer Attributmenge U ist genau dann faktorisiertbar bzgl. eines ungerichteten Graphen $G = (U, E)$, wenn G ein bedingter Unabhängigkeitsgraph für p_U ist.*

Einen Beweis dieses Satzes findet man z.B. in [27]. Er kann auf allgemeinere Verteilungen erweitert werden, z.B. auf Verteilungen über reellwertigen Attributen, vorausgesetzt, sie haben eine positive und stetige Dichtefunktion [27].


Für gerichtete Graphen wird der Begriff der Zerlegbarkeit bzw. Faktorisiertbarkeit in analoger Weise eingeführt. Der einzige Unterschied ist, dass man, entsprechend der Kantenrichtungen, bedingte Wahrscheinlichkeitsverteilungen benutzt.

Definition 3.7. *Eine Wahrscheinlichkeitsverteilung p_U über einer Attributmenge $U = \{A_1, \dots, A_n\}$ heißt zerlegbar oder faktorisiertbar bezüglich eines gerichteten azyklischen Graphen $\vec{G}$ genau dann, wenn sie geschrieben werden kann als Produkt der bedingten Wahrscheinlichkeiten der Attribute gegeben ihre Elternknoten in $\vec{G}$, d.h., wenn gilt $\forall a_1 \in \text{dom}(A_1) : \dots \forall a_n \in \text{dom}(A_n) :$*

$$p_U\left(\bigwedge_{A_i \in U} A_i = a_i\right) = \prod_{A_i \in U} P\left(A_i = a_i \mid \bigwedge_{A_j \in \text{parents}_{\vec{G}}(A_i)} A_j = a_j\right),$$

wobei $\text{parents}_{\vec{G}}(A_i)$ die Menge der Elternattribute des Attributes A_i in $\vec{G}$ ist.

Beispiel 3.3. *Die durch den rechts gezeigten, gerichteten azyklischen Graphen dargestellte Faktorisierung können wir ablesen, indem wir ein Produkt bilden, das einen Faktor für jedes Attribut enthält. Dieser Faktor gibt die bedingte Wahrscheinlichkeit eines Wertes dieses Attributes an, gegeben eine Belegung der Elternattribute. Wir erhalten so $\forall a_1 \in \text{dom}(A_1) : \dots \forall a_7 \in \text{dom}(A_7) :$*



$$\begin{aligned}
 p_U(A_1 = a_1 \wedge \dots \wedge A_7 = a_7) \\
 &= P(A_1 = a_1) \cdot P(A_2 = a_2 \mid A_1 = a_1) \cdot P(A_3 = a_3) \\
 &\cdot P(A_4 = a_4 \mid A_1 = a_1 \wedge A_2 = a_2) \cdot P(A_5 = a_5 \mid A_2 = a_2 \wedge A_3 = a_3) \\
 &\cdot P(A_6 = a_6 \mid A_4 = a_4 \wedge A_5 = a_5) \cdot P(A_7 = a_7 \mid A_5 = a_5).
 \end{aligned}$$

Für gerichtete azyklische Graphen gilt analog zu ungerichteten Graphen der Satz:

Theorem 3.2. *Eine Wahrscheinlichkeitsverteilung p_U über einer Attributmenge U ist genau dann faktorisiertbar bzgl. eines gerichteten azyklischen Graphen $\vec{G} = (U, \vec{E})$, wenn G ein bedingter Unabhängigkeitsgraph für p_U ist.*

Die Faktorisiertbarkeit lässt sich unmittelbar dadurch rechtfertigen, dass man den (verallgemeinerten) Produktsatz (Satz 2.3 auf Seite 8) auf die Verteilung p_U anwendet und die durch den Graphen dargestellten bedingten Unabhängigkeiten ausnutzt, um einige der bedingenden Attribute zu streichen [27].

Mit dem Begriff der Faktorisiertbarkeit bezüglich eines Graphen erhalten wir schließlich: Ein *Markow-Netz* ist ein ungerichteter bedingter Unabhängigkeitsgraph zusammen mit den Funktionen, die in der Zerlegung bezüglich dieses Graphen auftreten. Analog ist ein *Bayes-Netz* ein gerichteter azyklischer bedingter Unabhängigkeitsgraph zusammen mit den bedingten Wahrscheinlichkeitsverteilungen, die in der Zerlegung bezüglich dieses Graphen auftreten. Beide nennen wir *probabilistische (Schlussfolgerungs-)Netze* oder *probabilistische graphische Modelle*.

3.4 Evidenzpropagation

Um zu zeigen, wie man von einer Zerlegung zu einem Verfahren zur Evidenzpropagation in der zugehörigen Unabhängigkeitskarte gelangt, betrachten wir die formale Begründung der Evidenzpropagation aus Abb. 13 (Seite 21). Wie in den Erläuterungen zu der in Abb. 12 rechts dargestellten Schlussfolgerung im Gesamt-raum angegeben, besteht eine wahrscheinlichkeitstheoretische Schlussfolgerung in der Bestimmung der bedingten Wahrscheinlichkeiten der Werte eines Attributes gegeben die Werte der beobachteten Attribute. In diesem Beispiel haben wir, wenn wieder Attribut A für die Farbe, Attribut B für die Form und Attribut C für die Größe eines Objektes stehen, zunächst die bedingten Wahrscheinlichkeiten der Werte des Attributes B zu bestimmen, gegeben dass das Attribut A den Wert a_{obs} hat („obs“ für „observed“). D.h., wir müssen berechnen $\forall b \in \text{dom}(B)$:

$$\begin{aligned}
& P(B = b \mid A = a_{\text{obs}}) \\
&= P\left(\bigvee_{a \in \text{dom}(A)} A = a \wedge B = b \wedge \bigvee_{c \in \text{dom}(C)} C = c \mid A = a_{\text{obs}}\right) \\
&\stackrel{(1)}{=} \sum_{a \in \text{dom}(A)} \sum_{c \in \text{dom}(C)} P(A = a \wedge B = b \wedge C = c \mid A = a_{\text{obs}}) \\
&\stackrel{(2)}{=} \sum_{a \in \text{dom}(A)} \sum_{c \in \text{dom}(C)} P(A = a \wedge B = b \wedge C = c) \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)} \\
&\stackrel{(3)}{=} \sum_{a \in \text{dom}(A)} \sum_{c \in \text{dom}(C)} \frac{P(A = a \wedge B = b) \cdot P(B = b \wedge C = c)}{P(B = b)} \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)} \\
&= \sum_{a \in \text{dom}(A)} P(A = a \wedge B = b) \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)} \cdot \underbrace{\sum_{c \in \text{dom}(C)} P(C = c \mid B = b)}_{=1} \\
&= \sum_{a \in \text{dom}(A)} P(A = a \wedge B = b) \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)}.
\end{aligned}$$

In dieser Ableitung gilt (1) wegen der Kolmogorow-Axiome (Definition 2.2 auf Seite 7) und (3) wegen der bedingten Unabhängigkeit von A und C gegeben B (Seite 22), die es erlaubt, die Verteilung zu zerlegen. (2) gilt, da erstens

$$\begin{aligned}
& P(A = a \wedge B = b \wedge C = c \mid A = a_{\text{obs}}) \\
&= \begin{cases} \frac{P(A = a \wedge B = b \wedge C = c)}{P(A = a_{\text{obs}})}, & \text{falls } a = a_{\text{obs}}, \\ 0, & \text{sonst,} \end{cases}
\end{aligned}$$

und zweitens

$$\frac{P(A = a \wedge A = a_{\text{obs}})}{P(A = a)} = \begin{cases} 1, & \text{falls } a = a_{\text{obs}}, \\ 0, & \text{sonst,} \end{cases}$$

und folglich, unabhängig davon, ob $a = a_{\text{obs}}$ oder nicht,

$$\begin{aligned}
& P(A = a \wedge B = b \wedge C = c \mid A = a_{\text{obs}}) \\
&= P(A = a \wedge B = b \wedge C = c) \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)}.
\end{aligned}$$

Es ist klar, dass der linke Teil von Abb. 13 nur eine graphische Darstellung dieser Berechnungsformel für alle möglichen Werte des Attributes B ist.

Im zweiten Schritt der Evidenzpropagation haben wir die bedingten Wahrscheinlichkeiten der Werte des Attributes C zu berechnen, wieder gegeben, dass das Attribut A den Wert a_{obs} hat. D.h., wir müssen $\forall c \in \text{dom}(C)$ berechnen:

$$\begin{aligned}
 & P(C = c \mid A = a_{\text{obs}}) \\
 &= P\left(\bigvee_{a \in \text{dom}(A)} A = a \wedge \bigvee_{b \in \text{dom}(B)} B = b \wedge C = c \mid A = a_{\text{obs}}\right) \\
 &\stackrel{(1)}{=} \sum_{a \in \text{dom}(A)} \sum_{b \in \text{dom}(B)} P(A = a \wedge B = b \wedge C = c \mid A = a_{\text{obs}}) \\
 &\stackrel{(2)}{=} \sum_{a \in \text{dom}(A)} \sum_{b \in \text{dom}(B)} P(A = a \wedge B = b \wedge C = c) \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)} \\
 &\stackrel{(3)}{=} \sum_{a \in \text{dom}(A)} \sum_{b \in \text{dom}(B)} \frac{P(A = a \wedge B = b)P(B = b \wedge C = c)}{P(B = b)} \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)} \\
 &= \sum_{b \in \text{dom}(B)} \frac{P(B = b \wedge C = c)}{P(B = b)} \underbrace{\sum_{a \in \text{dom}(A)} P(A = a \wedge B = b) \cdot \frac{P(A = a \mid A = a_{\text{obs}})}{P(A = a)}}_{= P(B = b \mid A = a_{\text{obs}})} \\
 &= \sum_{b \in \text{dom}(B)} P(B = b \wedge C = c) \cdot \frac{P(B = b \mid A = a_{\text{obs}})}{P(B = b)}.
 \end{aligned}$$

(1), (2) und (3) gelten hier aus den gleichen Gründen wie oben. Es ist klar, dass der rechte Teil von Abb. 13 nur eine graphische Darstellung dieser Berechnungsformel für alle möglichen Werte des Attributes C ist.

Aus diesen Berechnungen lässt sich das sehr einfache Prinzip der Ableitung von Evidenzpropagationsformeln ablesen. Bei der Berechnung der bedingten Wahrscheinlichkeiten treten immer Summen über die Werte der anderen, nicht beobachteten Attribute auf. Wegen der Zerlegung der Verteilung kann man aus diesen Summen Faktoren, die nicht von der Summationsvariable abhängen, herausziehen. Die so umgeschriebenen Summen lassen sich vereinfachen. Entweder summieren sie alle bedingten Wahrscheinlichkeiten der Werte eines Attributes und sind folglich 1, oder sie sind bereits in einem früheren Schritt der Propagation berechnet worden.

Man beachte, dass diese Ableitung nicht auf ungerichtete Graphen beschränkt ist. Denn z.B. das Ergebnis der ersten Berechnung lässt sich ja auch schreiben als

$$P(B = b \mid A = a_{\text{obs}}) = P(B = b \mid A = a) \cdot P(A = a \mid A = a_{\text{obs}}),$$

was wegen der bedingten Wahrscheinlichkeit $P(B = b \mid A = a)$ einer Propagation entlang einer gerichteten Kante $A \rightarrow B$ entspricht. Diese Betrachtung erklärt auch den Namen *Bayes-Netz*, denn wäre die Kante $B \rightarrow A$ gerichtet, so müssten wir

$$P(B = b \mid A = a_{\text{obs}}) = \frac{P(A = a \mid B = b) \cdot P(B = b)}{P(A = a)} \cdot P(A = a \mid A = a_{\text{obs}})$$

berechnen, also die Bayessche Formel (Satz 2.5 auf Seite 9) anwenden, um die bedingte Wahrscheinlichkeit und damit gewissermaßen die Kante „umzudrehen“.

Man beachte weiter das typische Auftreten von Faktoren wie $\frac{P(A=a|A=a_{\text{obs}})}{P(A=a)}$ (für ungerichtete Graphen) oder nur $P(A = a \mid A = a_{\text{obs}})$ (für gerichtete Graphen), die man anschaulich *Evidenzfaktoren* nennen könnte, da sie die Evidenz wiedergeben, dass das Attribut A den beobachteten Wert a_{obs} hat. Im Prinzip kann man auch bei mehr als einem beobachteten Attribut mit einem solchen einfachen Evidenzfaktor für jedes beobachtete Attribut rechnen, wenn man berücksichtigt, dass man dann zur Normalisierung der Wahrscheinlichkeiten den Faktor

$$\gamma_{\text{norm}} = \frac{\prod_{A_i \in O} P(A_i = a_{i,\text{obs}})}{P(\bigwedge_{A_i \in O} A_i = a_{i,\text{obs}})}$$

hinzufügen muss, wobei O die Menge der beobachteten Attribute ist.⁷ Dieser Faktor kann in den Rechnungen vernachlässigt werden, da er für gegebene Beobachtungen konstant ist und daher durch eine Normalisierung ersetzt werden kann.

Mit der gleichen Vorgehensweise lassen sich leicht allgemeine Propagationsformeln für einfach zusammenhängende Unabhängigkeitskarten, also Bäume, ableiten. Auch wenn wir hier nicht auf alle Details eingehen können (ausführliche Darstellungen bieten z.B. [32], [20] oder [6]), wollen wir doch versuchen, die wesentlichen Prinzipien deutlich zu machen. Wir beschränken uns dazu (zunächst) auf einfache, ungerichtete Bäume. Wie wir schon in den Beispielen gesehen haben, laufen die Rechnungen i.W. in den Verbundverteilungen ab, die den Kanten entsprechen. Es ist daher hilfreich, diese Verteilungen in den Vordergrund zu setzen, was dadurch geschieht, dass man die Attribute in einem sogenannten *Verbundbaum* darstellt. In diesem bilden die Kanten, die die Verbundverteilungen repräsentieren, die Knoten. Diese Knoten werden so verbunden, dass wieder ein Baum entsteht.

Den Verbundbaum für das Beispiel aus Abschnitt 3.1 (hier gibt es nur eine Möglichkeit, während im allgemeinen Fall



Abbildung 15: Verbundbaum

Wahlmöglichkeiten bestehen können) zeigt Abb. 15. Man beachte, dass die einzige Kante in diesem Verbundbaum mit dem Schnitt der Attributmengen der Knoten, der auch als *Separatormenge* bezeichnet wird, belegt ist (Achtung: das Rechteck in der Mitte ist *kein* Knoten, sondern zeigt lediglich die Separatormenge der

⁷ Denn i.A. wird das Produkt der Wahrscheinlichkeiten der beobachteten Werte nicht mit ihrer gemeinsamen Wahrscheinlichkeit übereinstimmen.

einzigsten Kante). Die Evidenzpropagation in einem Verbundbaum, der aus einem ungerichteten, azyklischen Unabhängigkeitsgraphen (also einem ungerichteten Baum) erzeugt wurde, ist sehr einfach, da die Separatormengen immer nur ein Attribut enthalten, auf das marginalisiert werden muss und von dem aus, mit Hilfe des Faktors aus neuer und alter Wahrscheinlichkeit der Werte des Attributs, die verbundene Verbundverteilung aktualisiert wird.

Betrachten wir dazu die in Abb. 12 dargestellte Verteilung in Verbindung mit dem Verbundbaum aus Abb. 15. Wenn wir beobachten, dass das Objekt *weiß* ist, dann müssen wir die Verteilungen der anderen Attribute entsprechend anpassen. Gemäß dem Verbundbaum aktualisieren wir zuerst die Verteilung von „Farbe, Form“. Die 17% weiße Objekte stellen nun 100% der möglichen Objekte dar, was wiederum die Wahrscheinlichkeiten für die Form des Objektes beeinflusst (die nun 11.8%, 70.6% bzw. 17.6% für dreieckige, viereckige bzw. runde Objekte sind).

Die Veränderung der Verteilung des Attributes *Form* bewirkt wiederum eine Änderung der Verteilung des Attributes *Größe*, die in der rechts gezeigten Tabelle dargestellt ist. Damit ist die Evidenzpropagation für dieses sehr einfache Beispiel auch schon abgeschlossen. Die durchgeführten Berechnungen entsprechen im Wesentlichen den Berechnungen, die wir schon in Abb. 13 gesehen haben.

	k	m	g	
	6	53	59	△
	118	470	118	□
	88	59	29	○

Abbildung 16:
Neue Verteilung
Form × Größe

Mit dem Verbundbaumverfahren werden nach und nach alle Verbundverteilungen und Separatorwahrscheinlichkeiten gemäß der erhaltenen Evidenz angepasst. Indem jeweils innerhalb eines Verbundbaumknotens die Verteilung neu berechnet wird, werden die an andere Verbundbaumknoten weitergereicht. In diesen werden wieder die zugehörigen Verteilungen neu berechnet usw.

Auf einem Baum lässt sich auch die Verbundverteilung über alle Attribute leicht angeben (vgl. Abschnitt 3.2). Hat man einen zyklensfreien, ungerichteten Unabhängigkeitsgraphen $G = (V, E)$, mit $V = \{A_1, \dots, A_n\}$, so gilt $\forall a^{(1)}, \dots, a^{(n)}$:

$$P(A_1 = a^{(1)} \wedge \dots \wedge A_n = a^{(n)}) = \left(\prod_{A \in V} P(A) \right) \cdot \left(\prod_{\{A, B\} \in E} \frac{P(A \wedge B)}{P(A) \cdot P(B)} \right).$$

Mit Hilfe dieser Formel lassen sich die allgemeinen Propagationsformeln, die wir oben anschaulich anhand eines Verbundbaums beschrieben haben, recht leicht ableiten. Im Grunde geht man auf die gleiche Weise vor wie in dem oben betrachteten Beispiel: Für ein beobachtetes Attribut wird ein Evidenzfaktor hinzugefügt. Für ein Zielattribut, für dessen Werte wir die neuen Wahrscheinlichkeiten berechnen wollen, summieren wir die obige Zerlegungsformel über alle anderen Attribute. Dann können wir Faktoren, die nicht von bestimmten Summationsvariablen abhängen, aus den zugehörigen Summen herausziehen und erhalten so am Ende eine Art Kettenrechnung für die Evidenzpropagation, die die

Information von Kante zu Kante (also von Knoten zu Knoten des Verbundbaums) weitergibt. Die Form der einzelnen Rechenschritte ist stets die gleiche wie schon in dem mehrfach betrachteten Beispiel: es werden Quotienten aus neuer und alter Wahrscheinlichkeit der verschiedenen Attributwerte gebildet, mit denen eine zugehörige Verbundverteilung multipliziert wird. Diese wird dann auf das jeweils andere Attribut marginalisiert (durch Summation über die Werte des ersten Attributes).

Bei der Verallgemeinerung dieses Verfahrens treten i.W. zwei Probleme auf, die sich jedoch recht leicht lösen lassen. Erstens treten u.U. gewisse technische Schwierigkeiten auf, wenn Evidenz für mehr als ein Attribut vorliegt. Dies kann man z.B. dadurch lösen, dass man die Evidenz über mehrere Attribute Schritt für Schritt einbezieht: Erst propagiert man die Evidenz eines ersten Attributes und aktualisiert alle Verteilungen des Verbundbaums. Dann propagiert man die Evidenz eines zweiten Attributes auf dem aktualisierten Verbundbaum. Der Nachteil dieses Verfahrens ist, dass dann für jedes Attribut, für das eine Evidenz vorliegt, der komplette Graph durchlaufen werden muss. Verfahren, wie sie z.B. in [6] oder [20] vorgestellt werden, benutzen stattdessen ein Nachrichtensystem, in dem die Knoten Nachrichten über Änderungen ihrer Verteilungen an ihre Nachbarn verschicken.

Ein zweites Problem besteht darin, dass sich Abhängigkeiten nur selten durch eine einfache Baumstruktur darstellen lassen. Das gerade vorgestellte Verfahren lässt sich aber nur auf Baumstrukturen anwenden. In der Praxis liegen dagegen oft Strukturen vor, in denen es mehrere Wege von einem Knoten zu einem anderen gibt. Dann kann es mit einem auf Bäumen basierenden Verfahren zu Berechnungsfehlern kommen. Der Grund für diese Berechnungsfehler ist, dass sich nur schwer verhindern lässt, dass eine Evidenz doppelt berücksichtigt wird, nämlich dann, wenn sie auf zwei verschiedenen Wegen zu einem Knoten gelangt. Eine mehrfache Einrechnung der gleichen Evidenz kann jedoch zu falschen Ergebnissen führen, da die Einrechnung i.W. aus der Multiplikation mit einem Faktor besteht. In einer formalen Ableitung der Formeln für die Evidenzpropagation zeigt sich dies dadurch, dass man nicht zu einer einfachen Kettenrechnung kommt, wie sie für das oben besprochene Verfahren notwendig wäre, sondern komplexere Formeln erhält.

Um mit diesem Problem umzugehen, sind verschiedene Verfahren vorgeschlagen worden. Eines der bekanntesten ist die Cliquenbaum-Propagation (clique tree propagation) [26], bei dem ein mehrfach zusammenhängender Graph durch Zusammenfassen von Knoten in eine einfach zusammenhängende Struktur, einen Cliquenbaum, überführt wird. Details findet man z.B. in [6], [2] oder [24].

4 Ausblick

Die Verwendung von probabilistischen Modellen im Kontext industrieller Anwendungen bietet viel Potential kann jedoch auch erhebliche Herausforderungen mit sich bringen. Komplexe Rahmenbedingungen, sich ändernde Datenlagen und der Bedarf an nachvollziehbaren Entscheidungen erfordern robuste und anpassungsfähige Methoden. In diesem Kapitel werden daher drei zentrale Weiterentwicklungen vorgestellt: Verfahren zur Wissensrevision erlauben es, bestehendes Wissen unter neuen Bedingungen konsistent anzupassen. Methoden zum Lernen aus Daten helfen dabei, relevante Strukturen aus Beobachtungen zu extrahieren. Und schließlich ermöglichen neue Ansätze zur Erschließung kausaler Beziehungen ein tieferes Verständnis der zugrunde liegenden Mechanismen – eine Voraussetzung für begründete Interventionen in technischen und wirtschaftlichen Systemen.

4.1 Wissensrevision

Mit Hilfe der Evidenzpropagation berechnet man effektiv bedingte Wahrscheinlichkeitsverteilungen, wobei die gemachten Beobachtungen die Bedingungen darstellen. Im Englischen spricht man daher auch von *conditioning* oder *focusing* der Verteilung bzgl. der durch Beobachtung gegebenen Evidenz. In industriellen Anwendungen tritt aber auch das Problem auf, eine Wahrscheinlichkeitsverteilung, die durch ein graphisches Modell dargestellt wird, so anzupassen, dass sie bestimmten Rahmenbedingungen genügt, z.B. vorgegebenen Randverteilungen.

Dieses Problem tritt z.B. in einem System auf, in dem der Fahrzeughersteller Volkswagen Markow-Netze für Teilebedarfsplanung und Kapazitätsmanagement einsetzt [12]. In dieser Anwendung müssen die Wahrscheinlichkeiten von Kombinationen von Ausstattungsmerkmalen (das durch das graphische Modell dargestellte Wissen) so angepasst werden, dass bestimmte bedingte oder Randverteilungen erfüllt sind, die sich z.B. aus Kapazitätsgrenzen, technischen Regeln, Verkaufsprogrammen oder der Dynamik der Kundenwahlen verschiedener Ausstattungsoptionen ergeben. Ein *altes* Markow-Netz muss dazu so revidiert werden, dass das *neue*, revidierte Netz vorgegebene Randverteilungen besitzt. Dabei sollen nur die numerischen Parameter des Netzes verändert werden, seine Struktur (sein Graph und die durch ihn ausgedrückten bedingten Unabhängigkeiten) dagegen erhalten bleiben.

Weiter kann man fordern, dass bedingte Abhängigkeiten (bestimmt über geeignete Abhängigkeitsmaße) gleich bleiben oder sich nur so wenig wie möglich ändern. Dies entspricht einem Prinzip, das aus Ansätzen zur Theorierevision

in der klassischen Logik bekannt ist, die z.B. auf der Basis kontrafaktischer Annahmen durchgeführt wird [11], nämlich das *Prinzip der minimalen Änderung*. Dieses Prinzip besagt, dass man das vorhandene Wissen nur so wenig wie möglich ändern sollte, um die gegebenen (neuen) Randbedingungen zu erfüllen. Für ein Markow-Netz bedeutet dies, dass die neuen Verteilungsbedingungen erfüllt sind, aber nur minimale Änderungen der qualitativen und quantitativen Interaktionsstrukturen vorgenommen wurden [12]. Das neue Netz hat die gleichen Cliques wie das alte und auch die Kreuzprodukte der (Rand-)Verteilungen, die nicht von Revisionsinformationen betroffen sind, bleiben erhalten. Die Änderung der durch das gesamte Netz dargestellten Wahrscheinlichkeitsverteilung kann z.B. mit der Kullback-Leibler-Informationsdivergenz [25], einem klassischen Maß für die Verschiedenheit von Wahrscheinlichkeitsverteilungen, gemessen werden.

Dieses Anpassungsproblem kann unter Rückgriff auf Konzepte der multivariaten Statistik, insbesondere des iterativen proportionalen Anpassens (*iterative proportional fitting*) [50] gelöst werden [12]. Das Prinzip dieses Ansatzes, angewendet auf die Revision von Markow-Netzen, besteht darin, der Reihe nach die (Rand-)Verteilungen, die bestimmte Bedingungen erfüllen müssen, anzupassen, und diese Änderung analog zur Evidenzpropagation im Netz zu verbreiten. Da hierbei mit Faktoren multipliziert wird, die sich aus dem Verhältnis einer neuen zu einer alten Wahrscheinlichkeit ergeben, handelt es sich um *proportionales Anpassen*. Durch die Ausbreitung der Anpassung im Netz können aber bereits angepasste Verteilungen wieder geändert werden, so daß die Anpassung mehrfach wiederholt, also *iteriert*, werden muss. Man kann zeigen, dass diese Iteration auf eine Verteilung konvergiert, die die gewünschten Randverteilungen besitzt [50]. Die erfolgreiche Anwendung bei Volkswagen [12] zeigt, dass dies ein praktisch relevantes Verfahren ist, mit dem Planung und Kapazitätsmanagement gemeistert werden können.

4.2 Lernen aus Daten

Bisher haben wir unberücksichtigt gelassen, wie man denn eine geeignete Unabhängigkeitskarte für einen gegebenen Weltausschnitt findet. Das klassische Vorgehen ist, einen menschlichen Experten zu bitten, einen solchen Graphen anzugeben. Oft wird dieser dann von einem kausalen Modell des betrachteten Weltausschnitts ausgehen und einfach die (vermuteten) kausalen Einflüsse mit den gerichteten Kanten eines Bayes-Netzes identifizieren. Dieses Vorgehen macht zwar starke Annahmen über die Art und Weise, in der sich kausale Beziehungen statistisch zeigen (insbesondere setzt es voraus, dass ein Netz kausaler Beziehungen die durch die *d*-Trennung ablesbaren stochastischen Unabhängigkeiten zeigt),

Tabelle 1: Auswahlkriterien für relationale Projektionen.

Unterraum	relative Anzahl möglicher Wertkombinationen	Gewinn an Hartley-Information
Farbe×Form	$\frac{6}{12} = \frac{1}{2} = 50\%$	$\log_2 \frac{12}{6} = 1$
Farbe×Größe	$\frac{8}{12} = \frac{2}{3} \approx 67\%$	$\log_2 \frac{12}{8} \approx 0.58$
Form×Größe	$\frac{5}{9} = \frac{5}{9} \approx 56\%$	$\log_2 \frac{9}{5} \approx 0.85$

doch ist es oft erfolgreich. Die bedingten Wahrscheinlichkeiten des Bayes-Netzes werden anschließend vom Experten geschätzt oder mit statistischen Verfahren aus Erfahrungsdaten bestimmt.

Man kann jedoch auch versuchen, eine Zerlegung automatisch zu finden, indem man eine Datenbank von Beispielfällen analysiert. Das Prinzip eines solchen Lernens aus Daten erläutern wir hier kurz anhand des oben betrachteten relationalen Beispiels. Nehmen wir an, es sei die Tabelle aus Abb. 3 auf Seite 15 gegeben. Wir suchen eine (möglichst gute) Zerlegung in Projektionen auf zweidimensionale Unterräume. Wir könnten alle Möglichkeiten ausprobieren, jeweils die zusätzlichen Würfel zählen und schließlich die Möglichkeit mit der geringsten Zahl zusätzlicher Würfel wählen. Ein solches Verfahren ist allerdings für praktische Probleme wegen der sehr großen Zahl an Möglichkeiten nicht brauchbar. Angenehm wäre es, wenn man an einer Projektion ablesen könnte, ob sie für eine Zerlegung benötigt wird oder nicht. In der Tat lässt sich eine Heuristik angeben, die solche Einzelbewertungen durchführt und gute Chancen verspricht, eine geeignete Zerlegung zu finden.

Die diesem Verfahren zugrundeliegende Idee ist sehr einfach: Der Schnitt der zylindrischen Erweiterungen der Projektionen soll möglichst wenige (zusätzliche) Wertkombinationen enthalten, um die gegebene Relation gut anzunähern. Es ist plausibel, dass der Schnitt wenige Wertkombinationen enthält, wenn dies schon für die zylindrischen Erweiterungen gilt. Die Zahl der Kombinationen in einer zylindrischen Erweiterung wird aber direkt von der Zahl der Wertkombinationen in der Projektion bestimmt. Wir sollten daher Projektionen wählen, in denen möglichst wenige Wertkombinationen vorkommen.

Allerdings sollte man die unterschiedlichen Größen der Unterräume berücksichtigen — denn in großen Unterräumen wird es i.A. mehr mögliche Kombinationen geben, ohne dass dies etwas über die Zerlegbarkeit zu besagen hätte — und deshalb nicht die absolute, sondern die relative Zahl der Wertkombinationen bestimmen. Für unser Beispiel sind die Werte dieses Kriteriums in der zweiten Spalte der Tabelle 1 angegeben. Offenbar führt eine Auswahl der beiden Projektionen mit den kleinsten Werten zu der richtigen Zerlegung. In der dritten Spalte ist der

Logarithmus zur Basis 2 dieser Anzahlen berechnet, den man auch als Hartley-Informationsgewinn bezeichnet [17]. Für die Auswahl von Randverteilungen einer mehrdimensionalen Wahrscheinlichkeitsverteilung (statt Relation) lassen sich ähnliche Heuristiken angeben, wie z.B. der Shannon-Informationsgewinn [8, 25, 43].

Ein Verfahren zum Lernen eines Bayesschen Netzes, das auf einem Bayesschen Ansatz (im Sinne des Bayesschen Satzes) beruht, wurde in [7] und [18] vorgeschlagen und genauer untersucht: Mit Hilfe eines Bewertungsmaßes werden Elternmengen bestimmt. Weiter gibt es Ansätze, eine geeignete Netzstruktur abzuleiten, indem bedingte Unabhängigkeitstests durchgeführt werden, um für Variablenpaare (möglichst kleine) Bedingungs Mengen zu finden, unter denen sie unabhängig werden (siehe z.B. [33, 45]). Ein solcher Ansatz wird im nächsten Abschnitt besprochen, da er auch benutzt werden kann, um (Hinweise auf) kausale Beziehungen zu finden. Einen Überblick über weitere Lernverfahren findet man z.B. in [2, 21].

4.3 Erschließen kausaler Beziehungen

Im Abschnitt 3 haben wir gesehen, wie Graphen zur Darstellung einer Menge bedingter Unabhängigkeiten eingesetzt werden können. Speziell gerichtete Graphen legen aber eine weitergehende Interpretation nahe. Zwar sind die Kantenrichtungen zunächst nur eine anschauliche Kodierung bedingter Unabhängigkeiten oder zeigen (in der Faktorisierungssicht) an, welche Attribute als Bedingungen in den benötigten bedingten Wahrscheinlichkeitsverteilungen auftreten. Aber die Kantenrichtung ist zumindest sehr suggestiv und wird daher gern als kausale Beziehung zwischen einer Ursache und einer Wirkung gedeutet. Die Tatsache, dass Bayessche Netze ursprünglich *causal belief networks* genannt wurden, legt davon Zeugnis ab. Auch zeigt dies die (oben bereits erwähnte) übliche Praxis, Bayessche Netze zu entwerfen, indem man ein Netzwerkmodell der kausalen Einflüsse eines Weltausschnitts erstellt, das dann in eine gerichtete Unabhängigkeitskarte umgewandelt wird. In vielen Fällen funktioniert dieses Vorgehen auch erstaunlich gut — trotz der sehr starken impliziten, in bestimmten Weltausschnitten ggf. nicht erfüllten Annahmen.

Damit stellt sich die naheliegende Frage, ob sich durch das Lernen der Struktur gerichteter graphischer Modelle aus Daten etwas über kausale Beziehungen erfahren lässt; vielleicht nicht sicher und nicht umfassend, aber doch ansatzweise. Natürlich muss man auch hier berücksichtigen, dass allein aus Korrelation oder allgemein stochastischer Abhängigkeit nicht auf Kausalität geschlossen werden




Abbildung 17: Drei kausale Grundstrukturen und zugehörige bedingte Unabhängigkeiten.

kann.⁸ Aber Korrelation kann Hinweise auf mögliche kausale Beziehungen liefern, und Lernverfahren für graphische Modelle könnten vielleicht bessere Hinweise liefern, weil sie nicht aus einfachen Abhängigkeiten sondern der stochastischen Struktur mehrerer Variablen und den zwischen ihnen bestehenden bedingten Unabhängigkeiten bestimmt wurden. Übersichten findet man z.B. in [34, 35, 36].

Grundlage des Erschließens kausaler Beziehungen aus bedingten Unabhängigkeiten ist eine Überlegung, die auf Hans Reichenbach zurückgeht [38]. Diesem ging es zwar eigentlich um das Problem der Zeitrichtung in der Physik: Warum ist eine Zeitrichtung ausgezeichnet, die Zeit nicht umkehrbar? (Im Gegensatz zum Raum, in dem man sich in beliebige Richtungen bewegen kann.) Der Bezug zur Kausalität wird dadurch hergestellt, dass nach unserem üblichen Verständnis eine Ursache ihrer Wirkung zeitlich vorangehen muss. Wenn es gelingt, Kausalität über bedingte Unabhängigkeiten und ohne Rückgriff auf die Zeit zu definieren, dann hat man auch eine Erklärung für die Zeitrichtung gefunden.

Dazu betrachtete Reichenbach die drei kausalen Grundstrukturen, die in Abb. 17 gezeigt sind [38]. In einer kausalen Kette verursacht eine Ursache A vermittelt über eine Zwischengröße C eine Wirkung B . Deutet man den zugehörigen Graphen als Unabhängigkeitskarte (Definition 3.5 auf Seite 26) und liest die gemäß d -Trennung geltenden bedingten Abhängigkeiten und Unabhängigkeiten ab, so erhält man, dass A und B abhängig sind, solange C nicht gegeben ist, aber unabhängig werden, wenn man C festhält. Ähnlich sieht es aus, wenn eine Ursache zwei verschiedene Wirkungen hat (Abb. 17 mitte): Solange die Ursache C nicht gegeben ist, sind die beiden Wirkungen A und B abhängig. Aber sie werden unabhängig, wenn man die Ursache C festhält. Grundsätzlich verschieden ist aber die dritte Struktur (Abb. 17 rechts): Erzeugen zwei Ursachen A und B (gemeinsam oder einzeln) eine Wirkung C , dann ist die Situation genau umgekehrt: A und B sind unabhängig, solange C , die Wirkung, *nicht* gegeben ist, werden aber *abhängig*, wenn man C festhält. Es besteht eine fundamentale Asymmetrie.

⁸ Das klassische Beispiel ist die deutliche Korrelation zwischen der Zahl der freilebenden Störche und der Zahl der Neugeborenen, die ca. von 1965 bis 1980 bestand [44].

Diese Sicht ist sehr plausibel, wie Beispiele zeigen: In der kausalen Kette sei A die Position des Gaspedals eines Fahrzeugs, C die zugeführte Kraftstoffmenge und B die Motordrehzahl. Hält man die zugeführte Kraftstoffmenge konstant, verschwindet die vorher bestehende Abhängigkeit von Pedalposition und Motordrehzahl. Bei der gemeinsamen Ursache sei A der Speiseeisumsatz, B die Zahl der Badeunfälle und C die Außentemperatur. Solange die Außentemperatur nicht auf einem Wert festgehalten (oder Daten mit einem festen Wert ausgewählt) werden, besteht eine Abhängigkeit zwischen dem Speiseeisumsatz und der Zahl der Badeunfälle: beide sind um so höher, je wärmer es ist — letztere, weil bei warmem Wetter mehr Menschen baden gehen, wodurch auch mehr beim Baden verunglücken. Bei einer gemeinsamen Wirkung beschreibe A das Vorliegen einer Grippeerkrankung, B das Vorliegen einer Masernerkrankung und C das Auftreten von Fieber. Solange über die Körpertemperatur nichts bekannt ist, haben Grippe und Masern nichts miteinander zu tun (sie sind unabhängig), aber wenn man das Auftreten von Fieber festhält, so erhält man daraus, dass keine Grippe vorliegt, eine höhere Wahrscheinlichkeit für Masern, weil das Fieber eine Ursache haben muss. Besonders deutlich wird dies, wenn wir vereinfachend annehmen, dass nur Grippe und Masern Fieber verursachen können: dann kann bei Vorliegen von Fieber aus der Abwesenheit der einen Krankheit sicher auf das Vorliegen der anderen geschlossen werden.

Auf dieser Grundlage wurde in [33] ein Algorithmus entwickelt, der *inductive causation algorithm*, mit dem man versuchen kann, mit Hilfe der Ergebnisse von bedingten Unabhängigkeitstests, die man zwischen den Attributen eines Weltausschnitts durchführt, zumindest eine teilweise gerichtete Struktur kausaler Abhängigkeiten zu erschließen. Obwohl dieser Algorithmus recht hübsch ist und in vielen Fällen durchaus sinnvolle Ergebnisse liefern kann, sollte man seine Mächtigkeit nicht überschätzen. Er beruht auf einigen sehr starken und keineswegs unproblematischen Annahmen, durch die die Sicherheit des Ergebnisses nicht garantiert werden kann. Diese Annahmen sowie die genaue algorithmische Form des Vorgehens gehen jedoch über dieses Kapitel weit hinaus. Eine genaue Untersuchung und Kritik der Annahmen, die auf die oben betrachteten kausalen Grundstrukturen zurückgeht und insbesondere in der stochastischen Interpretation der Struktur mit gemeinsamer Ursache ein schwerwiegendes Problem erblickt, findet man in [1].

Die Grundidee des Algorithmus soll aber an einem ganz einfachen Beispiel kurz erläutert werden. Wir nehmen an, dass ein Weltausschnitt durch vier Attribute A , B , C und D beschrieben werden kann (Abb. 18 links). Weiter nehmen wir an, dass umfangreiche Tests auf bedingte Unabhängigkeit das Ergebnis erbrachten, dass nur folgende bedingte Unabhängigkeiten gelten: $A \perp\!\!\!\perp B \mid \emptyset$, $A \perp\!\!\!\perp D \mid C$, $B \perp\!\!\!\perp D \mid C$ (sowie die aus diesen mit Hilfe der Semi-Graphoid-Axiome, Definiti-




Abbildung 18: Erschließen einer kausalen Struktur aus bedingten Unabhängigkeiten.

on 3.2 auf Seite 23, ableitbaren). Alle anderen Paare von Attributen seien stets abhängig, unabhängig davon, welche Bedingungen gewählt werden, und auch die in der Liste auftretenden Paare von Attributen seien abhängig unter allen anderen Bedingungen.

Es folgt, dass es in einer (gerichteten) Unabhängigkeitskarte zwischen A und C , zwischen B und C und zwischen C und D Kanten geben muss, denn es gibt ja nach unserer Annahme keine bedingten Unabhängigkeiten für diese Variablenpaare. Das ist aber nur möglich, wenn sie durch eine Kante verbunden sind. Damit erhalten wir die in Abb. 18 in der Mitte gezeigte Struktur, die man ein Skelett des gesuchten gerichteten Graphen nennen kann, weil nur die benötigten Kanten eingetragen sind, sie aber noch keine Richtung zugewiesen bekommen haben.

Diese Richtungen werden im letzten Schritt bestimmt. Wir wissen z.B., dass $A \perp\!\!\!\perp B \mid \emptyset$ gilt, aber $A \perp\!\!\!\perp B \mid C$ nicht. Das ist aber bei einer Struktur, bei der zwei Variablen (hier A und B) mit einer dritten (hier C), aber nicht miteinander verbunden sind, nur möglich, wenn es sich um die Situation einer gemeinsamen Wirkung handelt (Abb. 17 rechts). Folglich müssen die Kanten von A nach C und von B nach C zeigen (Abb. 18 rechts). Dass außerdem die verbleibende Kante von C nach D gerichtet sein muss, erhält man wie folgt: Wir wissen, dass $A \perp\!\!\!\perp D \mid C$ gilt, aber $A \perp\!\!\!\perp D \mid \emptyset$ nicht. Die einzige Struktur von zwei Variablen (hier A und D), die jeweils mit einer dritten (hier C) verbunden sind, aber nicht miteinander, die diese bedingten (Un-)Abhängigkeiten und die bereits bekannte Kantenrichtung (von A nach C) erfüllt, ist die kausale Kette (Abb. 17 links). Folglich muss die Kante von C nach D gerichtet sein. Man beachte, dass man das gleiche Ergebnis erzielt, wenn man von $B \perp\!\!\!\perp D \mid C$ und $B \not\perp\!\!\!\perp D \mid \emptyset$ ausgeht.

Das Erschließen kausaler Beziehungen ist in den vergangenen Jahren immer populärer geworden und ein wesentlicher und vielversprechender Zweig der aktuellen Forschung im Bereich der probabilistischen graphischen Modelle [34, 36, 35]. Speziell Judea Pearl hat argumentiert, dass die Entwicklung “echter” künstlicher Intelligenz erfordert, mit kausalen Beziehungen Schlüsse ziehen und kausale Beziehungen erschließen zu können [35].

5 Schlussbetrachtungen

Das Buchkapitel bietet zunächst eine Einführung in die mathematische Modellierung von unsicherem und unscharfem Wissen. Anschließend wird gezeigt, wie solches Wissen verarbeitet werden kann, etwa durch das Ziehen von Schlussfolgerungen. In der Frühphase der Künstlichen Intelligenz kamen hierfür vor allem heuristische Modelle zum Einsatz, wie beispielsweise die Sicherheitsfaktoren im Expertensystem MYCIN. Allerdings hat sich gezeigt, dass solche heuristischen Ansätze oft nicht ausreichen, um zentrale Anforderungen wie Erklärbarkeit, Flexibilität, Robustheit und Leistungsfähigkeit in realen Anwendungen zu erfüllen.

In diesem Kapitel wurden exemplarisch je eine Methodik zur Handhabung unsicheren bzw. unscharfen Wissens vorgestellt, mit denen die Autoren in zahlreichen praktischen Anwendungen erfolgreich gearbeitet haben. Eine ausführliche Darstellung dieser Methoden und ihrer Einsatzgebiete bietet das weiterführende Lehrbuch der Autoren [24].

Bei der Modellierung *unsicheren Wissens* haben sich insbesondere probabilistische Ansätze bewährt. Hierbei kommen probabilistische graphische Modelle – wie Bayes'sche Netze und Markow-Netze – zum Einsatz, die sich in der Praxis, insbesondere bei Aufgaben der Planung, Diagnose und Entscheidungsfindung, etabliert haben. Neben leistungsfähigen Schlussfolgerungsverfahren werden auch Methoden zur Strukturlernen und zur Schätzung der Wahrscheinlichkeiten diskutiert. Für den Einsatz in realen Systemen ist zudem die Verfügbarkeit effizienter Verfahren zur Wissensrevision von zentraler Bedeutung. Abschließend werden im Kapitel das Erschließen kausaler Beziehungen skizziert. Der Vorteil dieser Verfahren besteht darin, dass Wahrscheinlichkeitsverteilungen und Bayes'sche Modelle mit Unsicherheiten explizit modelliert werden und Entscheidungen unter Unsicherheit getroffen werden können. Darüber hinaus können sie verwendet werden, um komplexe Modelle (z.B. tiefe Neuronale Netze) zu erklären und damit Risiken in KI-Systemen zu erkennen [14]. Die Transparenz über Unsicherheiten stärkt das Vertrauen und die Akzeptanz in die Resultate.

Neben probabilistischen Verfahren existieren weitere mathematisch fundierte Ansätze zur Modellierung unsicheren Wissens wie die Possibilitätstheorie oder die Verwendung von Belief Functions. Auch gibt es viele nützliche Methoden zur (nachträglichen) Quantifizierung von Unsicherheit in gelernten KI-Systemen (z.B. LIME [39] und SHAP [29]), auf die wir in diesem kurzen Kapitel nicht eingehen können.

Unscharfes Wissen lässt sich hingegen besonders gut durch mehrwertige Logiken modellieren. Die sogenannten Fuzzy-Logiken erlauben den Umgang mit vagen, ungenauen oder mehrdeutigen Daten und Regeln. Einige dieser Logiken,

etwa die Łukasiewicz-Logik mit Wahrheitswerten aus dem Einheitsintervall, wurden bereits in den 1920er-Jahren diskutiert [28]. In Anwendungen kommen oft Fuzzy-Mengen zum Einsatz. Deren Elemente werden Zugehörigkeitsgrade im Intervall $[0,1]$ zugeordnet, die als Wahrheitswerte einer mehrwertigen Logik interpretiert werden.

Fuzzy-Systeme sind besonders in der industriellen Steuerungs- und Regelungstechnik weit verbreitet. Sie kommen überall dort zum Einsatz, wo komplexe, dynamische Prozesse zu steuern oder zu regeln sind, deren Zusammenhänge sich nur schwer mathematisch exakt beschreiben lassen. In der Praxis sind hybride Modelle [24] häufig erforderlich, da unsicheres und unscharfes Wissen oft gemeinsam auftritt.

Literaturverzeichnis

- [1] C. Borgelt und R. Kruse. Probabilistic Networks and Inferred Causation. *Cardozo Law Review* 18(6):2001–2035 Cardozo School of Law, Yeshiva University, New York, NY, USA 1997
- [2] C. Borgelt, M. Steinbrecher und R. Kruse. *Graphical Models — Representations for Learning, Reasoning and Data Mining* (2nd edition). J. Wiley & Sons, Chichester, Großbritannien 2009
- [3] C. Borgelt und R. Kruse. Bedeutung von Zugehörigkeitsgraden in der Fuzzy-Technologie. *Informatik-Spektrum* 38(6):490–499 Springer, Berlin/Heidelberg, Deutschland 2015
- [4] B.G. Buchanan und E.H. Shortliffe. *Rule-Based Expert Systems: The MYCIN Experiments of the Stanford Heuristic Programming Project*. Addison-Wesley, Reading, MA, USA 1984
- [5] R. Carnap. *Introduction to Symbolic Logic and Its Applications*. Dover, New York, NY, USA 1958
- [6] E. Castillo, J.M. Gutierrez und A.S. Hadi. *Expert Systems and Probabilistic Network Models*. Springer, New York, NY, USA 1997
- [7] G.F. Cooper und E. Herskovits. A Bayesian Method for the Induction of Probabilistic Networks from Data. *Machine Learning* 9:309–347. Kluwer, Dordrecht, Niederlande 1992
- [8] C.K. Chow und C.N. Liu. Approximating Discrete Probability Distributions with Dependence Trees. *IEEE Trans. on Information Theory* 14(3):462–467. IEEE Press, Piscataway, NJ, USA 1968
- [9] C.J. Date. *An Introduction to Database Systems* (8th edition). Addison Wesley, Reading, MA, USA 2020
- [10] A. Dawid. Conditional Independence in Statistical Theory. *SIAM Journal on Computing* 41:1–31. Society of Industrial and Applied Mathematics, Philadelphia, PA, USA 1979
- [11] P. Gärdenfors. *Knowledge in Flux: Modeling the Dynamics of Epistemic States*. MIT Press, Cambridge, MA, USA 1988
- [12] J. Gebhardt, C. Borgelt und R. Kruse. Knowledge Revision in Markov Networks. *Mathware and Softcomputing* 11(2–3):93–107. University of Granada, Granada, Spain 2004
- [13] D. Geiger, T.S. Verma und J. Pearl. Identifying Independence in Bayesian Networks. *Networks* 20:507–534. J. Wiley & Sons, Chichester, Großbritannien 1990
- [14] Geiger, A., Lu, H., Icard, T. & Potts, C. Causal abstractions of neural networks. *Advances In Neural Information Processing Systems*. 34:9574–9586 United States, 2021

- [15] P. Hajek. *Metamathematics of Fuzzy Logic*. Kluwer, Dordrecht, Niederlande 1998
- [16] J.M. Hammersley und P.E. Clifford. *Markov Fields on Finite Graphs and Lattices*. Unveröffentlichtes Manuskript, 1971. Nach: [19]
- [17] R.V.L. Hartley. Transmission of Information. *The Bell Systems Technical Journal* 7:535–563. Bell Laboratories, Murray Hill, NJ, USA 1928
- [18] D. Heckerman, D. Geiger und D.M. Chickering. Learning Bayesian Networks: The Combination of Knowledge and Statistical Data. *Machine Learning* 20:197–243. Kluwer, Dordrecht, Niederlande 1995
- [19] V. Isham. An Introduction to Spatial Point Processes and Markov Random Fields. *Int. Statistical Review* 49:21–43. Int. Statistical Institute, Voorburg, Niederlande 1981
- [20] F.V. Jensen. *An Introduction to Bayesian Networks*. UCL Press, London, Großbritannien 1996
- [21] M.I. Jordan, ed. *Learning in Graphical Models*. MIT Press, Cambridge, MA, USA 1998
- [22] E.-P. Klement, R. Mesiar und E. Pap *Triangular Norms*. Kluwer, Dordrecht, Niederlande 2000
- [23] R. Kruse, J. Gebhardt und F. Klawonn. *Fuzzy Systeme (2. Auflage)*. Teubner, Stuttgart, Deutschland 1995
- [24] R. Kruse, S. Mostaghim, C. Borgelt, C. Braune, und M. Steinbrecher. *Computational Intelligence: A Methodological Introduction* (3rd edition). Springer, London, Großbritannien 2023
- [25] S. Kullback und R.A. Leibler. On Information and Sufficiency. *Annals of Mathematical Statistics* 22:79–86. Institute of Mathematical Statistics, Hayward, CA, USA 1951
- [26] S.L. Lauritzen und D.J. Spiegelhalter. Local Computations with Probabilities on Graphical Structures and Their Application to Expert Systems. *Journal of the Royal Statistical Society, Series B*, 2(50):157–224. Blackwell, Oxford, Großbritannien 1988
- [27] S.L. Lauritzen. *Graphical Models*. Oxford University Press, Oxford, Großbritannien 1996
- [28] J. Łukasiewicz. O logice trójwartościowej (polnisch). *Ruch filozoficzny* 5:170–171. Englische Übersetzung: On Three-Valued Logic. in: L. Borkowski, ed. *Selected works by Jan Łukasiewicz*. North-Holland, Amsterdam, 1970, 87–88
- [29] Lundberg, S. & Lee, S. A unified approach to interpreting model predictions. *Advances In Neural Information Processing Systems*. Red Hook, NY, USA 2017
- [30] D. Maier. *The Theory of Relational Databases*. Computer Science Press, Rockville, MD, USA 1983
- [31] J. Pearl und A. Paz. *Graphoids: A Graph Based Logic for Reasoning about*

- Relevance Relations* (Technical Report CSD-850038) University of California, Los Angeles, CA, USA 1985
- [32] J. Pearl. *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann, San Mateo, CA, USA 1988 (2nd edition 1992)
 - [33] J. Pearl und T.S. Verma. A Theory of Inferred Causation. *Proc. 2nd Int. Conf. on Principles of Knowledge Representation and Reasoning*, 441–452, Morgan Kaufman, San Mateo, CA, 1991
 - [34] J. Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, Cambridge, Großbritannien 2000
 - [35] J. Pearl und D. MacKenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, New York, NY, USA 2018
 - [36] J. Peters, D. Janzing und B. Schölkopf. *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press, Cambridge, MA, USA 2017
 - [37] H. Reichenbach. *Elements of Symbolic Logic*. Macmillan, New York, NY, USA 1947
 - [38] H. Reichenbach. *The Direction of Time*. Dover Publications, New York, NY, USA 1956
 - [39] Ribeiro, M., Singh, S. & Guestrin, C. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. *Proceedings Of The 22nd ACM SIGKDD International Conference On Knowledge Discovery And Data Mining*, 1135–1144, New York, NY, USA 2016
 - [40] W.C. Salmon. *Logic*. Prentice Hall, Englewood Cliffs, NJ, USA 1963
 - [41] L.J. Savage. *The Foundations of Statistics*. J. Wiley & Sons, New York, NY, USA 1954. Reprinted by Dover Publications, New York, NY, USA 1972
 - [42] U. Schöning. *Logik für Informatiker* (5. Auflage). BI Wissenschaftsverlag, Mannheim, Deutschland 2000
 - [43] C.E. Shannon. The Mathematical Theory of Communication. *The Bell Systems Technical Journal* 27:379–423. Bell Laboratories, Murray Hill, NJ, USA 1948
 - [44] H. Sies. A New Parameter for Sex Education. *Nature* 1988:332:495. Nature Publishing Group, London, Großbritannien 1988
 - [45] H. Steck. *Constraint-Based Structural Learning in Bayesian Networks using Finite Data Sets*. Dissertation, TU München, Deutschland 2001
 - [46] M. Studený. Conditional Independence Relations have no Finite Complete Characterization. *Trans. 11th Prague Conf. on Information Theory, Statistical Decision Functions, and Random Processes*, 377–396. Academia, Prague, Tschechoslowakei 1992
 - [47] J.D. Ullman. *Principles of Database and Knowledge-Base Systems, Vol. 1 & 2*. Computer Science Press, Rockville, MD, USA 1988
 - [48] T.S. Verma und J. Pearl. Causal Networks: Semantics and Expressiveness.

Machine Intelligence and Pattern Recognition, 69–76. Elsevier, Amsterdam, Niederlande 1990

- [49] C.F. Weizsäcker. *Zeit und Wissen*. Hanser, München, Deutschland 1992
- [50] J. Whittaker. *Graphical Models in Applied Multivariate Statistics*. J. Wiley & Sons, Chichester, Großbritannien 1990
- [51] L. Wittgenstein. *Philosophische Untersuchungen*. Suhrkamp, Frankfurt am Main, Deutschland 1984 (Erstveröffentlichung: Blackwell, Oxford, England 1953)
- [52] L.A. Zadeh. Fuzzy Sets. *Information and Control* 8:338–353, 1965. Academic Press, San Diego, CA, USA 1965